程序设计实习（实验班-2025春）
距离度量及其计算：高维欧氏距离

授课教师：姜少峰
助教：管晏如、孔启皓、楼家宁、杨卓凡

Email: shaofeng.jiang@pku.edu.cn

Curse of Dimensionality

高维欧氏空间的“奇怪”特性

区别于低维空间上的常见直觉

- 高维空间还有很多其他“奇怪”的特性
- 方 vs 圆：单位立方体的体积是1，单位球的体积是$O(2^{-O(d)})$

d维半径为r的球体积近似：$V_d(r) \approx \frac{1}{\sqrt{d\pi}} \left(\frac{2\pi e}{d}\right)^{d/2} \cdot r^d$

- 另：单位圆和方的直径差$\sqrt{d}$倍

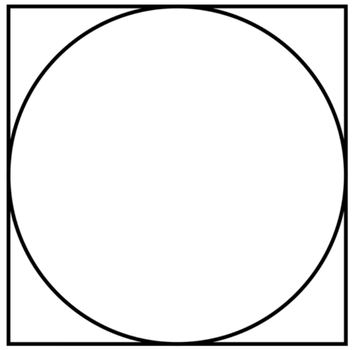

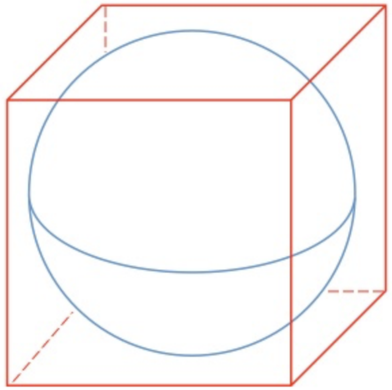

Dimension	Volume of a ball of radius R
0	1
1	$2R$
2	$\pi R^2 \approx 3.142 \times R^2$
3	$\frac{4\pi}{3} R^3 \approx 4.189 \times R^3$
4	$\frac{\pi^2}{2} R^4 \approx 4.935 \times R^4$
5	$\frac{8\pi^2}{15} R^5 \approx 5.264 \times R^5$
6	$\frac{\pi^3}{6} R^6 \approx 5.168 \times R^6$
7	$\frac{16\pi^3}{105} R^7 \approx 4.725 \times R^7$
8	$\frac{\pi^4}{24} R^8 \approx 4.059 \times R^8$
9	$\frac{32\pi^4}{945} R^9 \approx 3.299 \times R^9$
10	$\frac{\pi^5}{120} R^{10} \approx 2.550 \times R^{10}$
11	$\frac{64\pi^5}{10395} R^{11} \approx 1.884 \times R^{11}$
12	$\frac{\pi^6}{720} R^{12} \approx 1.335 \times R^{12}$
13	$\frac{128\pi^6}{135135} R^{13} \approx 0.911 \times R^{13}$
14	$\frac{\pi^7}{5040} R^{14} \approx 0.599 \times R^{14}$
15	$\frac{256\pi^7}{2027025} R^{15} \approx 0.381 \times R^{15}$
n	$V_n(R)$

Curse of Dimensionality

样本稀疏

- 考虑呈每一维坐标的均匀分布以及n个样本点P
  - 有2^d个潜在样本，因此经常$n \ll 2^d$
  - 这导致数据极为“稀疏”，很难形成对整个样本空间的有效覆盖/估计

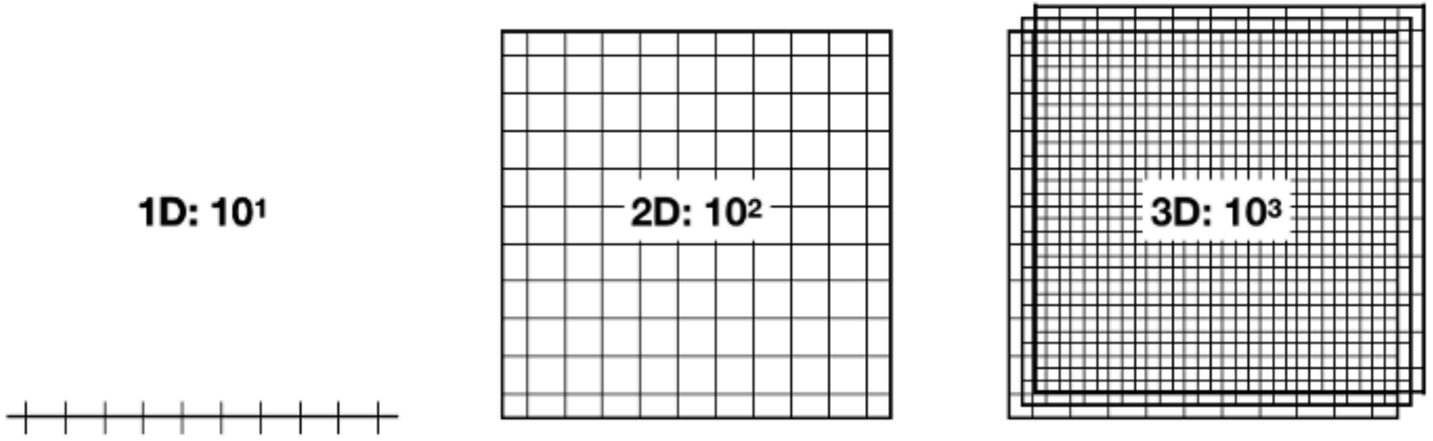

Curse of Dimensionality

对于计算问题的挑战

- 关于d的依赖经常是指数级的！
- 在若干计算模型和问题中，$d = O(\log n)$已经很难！
  - 例如，对于欧氏TSP，无多项式时间$(1+\epsilon)$-近似
  - 对于最近点对和直径问题，无$n^{2-\delta}$时间$(1+\epsilon)$-近似算法
  - 对于数据流MST/FL，无$o(n)$空间$(1+\epsilon)$近似

需要在某些例如$\mathrm{P} \neq \mathrm{NP}$的复杂度假设下

[Trevisan, SICOMP 00]

[Karthic et al., ITCS 19]; [Chen, CCC 18]

[Chen et al., STOC 23]; [Czumaj et al., FOCS 22]

$d = \Theta(\log n)$已经是高维

很多问题高维下无$(1+\epsilon)$近似

2^d vs $\mathrm{poly}(d)$

- 对于算法来说，关于d的依赖常常满足一个二分性：
  - 要么是$\mathrm{poly}(d)$，要么是至少2^d
  - 尤其是 $2^{\log^2 d}$ 这种quasi-poly的很罕见
- 因此：$\mathrm{poly}(d)$的是适用于高维的算法，而任意的$f(d)$的则是适用于低维的

例如2^{2^d}也是可以接受的

- 另一种理解方式是：低维即$d = O(1)$，高维即$d = O(\log n)$

高维欧氏距离上的高效近似技术

我们的侧重点

- 侧重运行快速、实现简便
- 代价是较大的（最坏情况下的）近似比，通常大于常数
- 本讲的近似比都与d有关，但后面的一讲会介绍如何能规约到$d = O(\log n)$
  - 本讲及其作业并不需要该规约

一个通用技术：随机平移四分树

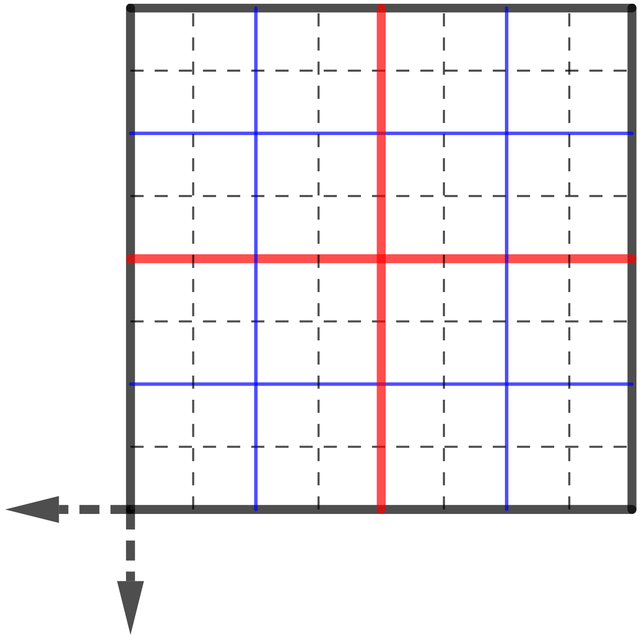

每维独立生成$[0,\Delta]$随机数

- 选取$[0,\Delta]^d$上的均匀随机向量v
- 构造四分树BuildTree$([0,2\Delta]^d, P)$后，将整个树平移$-v$
  - 也可以看作BuildTree$(\square = [-v,2\Delta - v]^d, P)$

$[0,2\Delta]$确保平移后依然覆盖点集

- 回忆：构造四分树复杂度为$O(nd\log\Delta)$，不需要2^d

- 我们将利用这同样的构造给出若干不同的应用方式

主要概率性质

称这种hypercube为2^i-cube

- 考虑一对点x, y，以及边长为2^i的hypercube，则

$$\Pr[x, y \text{ are cut by } 2^i\text{-cubes}] \leq \frac{\sqrt{d} \cdot \|x - y\|_2}{2^i}$$

这里cut的意思是说x, y不属于同一个2^i-cube

- 直觉：“小边被大cube分开的概率很低”

主要概率性质

$$\Pr[x, y \text{ are cut by } 2^i\text{-cubes}] = \Pr[\exists j \in [d], x, y \text{ are cut at coordinate } j \text{ of } 2^i\text{-cube}]$$

$$\leq \sum_{j \in [d]} \Pr[x, y \text{ are cut at coordinate } j \text{ of } 2^i\text{-cube}]$$

$$\leq \sum_{j \in [d]} |y_j - x_j| / 2^i \leq \frac{\sqrt{d}\|x - y\|_2}{2^i}$$

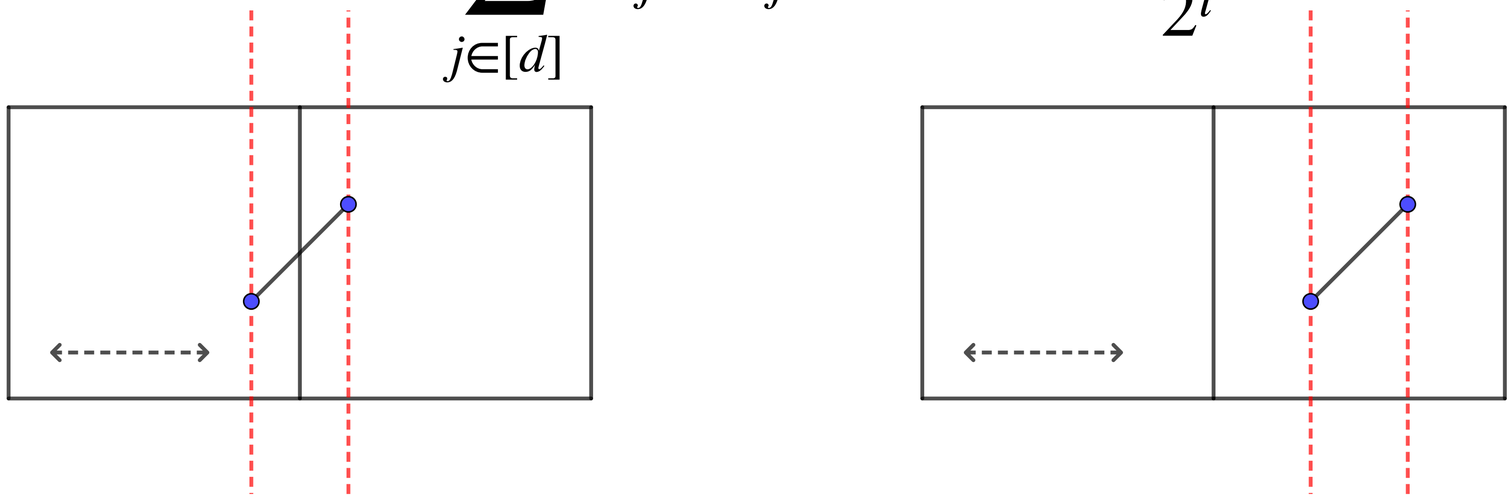

1. 随机平移四分树与 Spanner

高维Spanner

复习定义

$t \geq 1$

- t-Spanner是数据集$P \subseteq [\Delta]^d$的一个欧氏图的子图H
  - 欧氏图：点集还是P，边集是$P \times P$，边权重是端点间的欧氏距离
  - 子图：点集相同，边集是子集
  - t-Stretch：要求对任何$x, y \in P$有$\|x - y\| \leq \mathrm{dist}_H(x, y) \leq t \cdot \|x - y\|$
  - 追求：给定t，H满足t-stretch条件，且边数尽量少

dist_H代表H上的最短路距离

- 可看作是欧氏图的稀疏“压缩”，后续可使用稀疏图上的算法来解决欧氏问题

高维Spanner结论与算法

- 结论：存在一个$O(d)$-spanner，构造时间/边数$O(n\log(n)\log(\Delta))$
- 算法：初始化spanner边集$H \leftarrow \varnothing$
  - 设$m \leftarrow O(\log n)$，独立采样m个随机平移四分树$T_1, \ldots, T_m$
  - 对每个$j \in [m]$，每个树上的节点$u \in T_j$
    - 设P_u为u含有的数据点集合，将P_u上的任意一个星形图加入H

星形图：除了一个树根外其余全是叶子的树

- 边数、时空复杂度的分析?

作业十六：高维Spanner近似MST

- http://cssyb.openjudge.cn/25hw_16/
- Deadline: 5月7日
- 分值：2分

- 潜在的也可尝试tree embedding，但实际近似比可能略差（标程采用spanner）

分析

$$\Pr[x, y \text{ are cut by } 2^i\text{-cubes}] \le \frac{\sqrt{d} \cdot \|x - y\|_2}{2^i}$$

- 考虑任意的数据点x, y
- 我们需要spanner有一条$x \rightsquigarrow y$长度至多$O(d) \cdot \|x - y\|_2$路径
- 设i_{xy}满足$2^{i_{xy}} \approx \|x - y\|_2$
- 若存在T_j使x, y同属于某$O(\sqrt{d}) \cdot 2^{i_{xy}}$-cube，则已经找到了这样的路径

星形图的直径至多是$2\sqrt{d}$倍的cube直径

- 考虑反面：所有m个T_j都在$2^{i_{xy}}$-cube上分开x, y，概率至多是$2^{-m} = 1/\mathrm{poly}(n)$
- union bound后可以得出所有点对都满足$O(d)$的误差

2. 随机平移四分树与 Tree Embedding

Tree Embedding

- Tree embedding：将数据集P从$\mathbb{R}^d$映射到一棵树$T(V, E)$上，其中$P \subseteq V$
  - 旨在用树上的距离来“近似”/“代替”欧氏距离
  - 首先要求$\forall x, y \in P$，$\mathrm{dist}_T(x, y) \geq \|x - y\|$
- 主要性能衡量叫distortion:

$$\max_{x \neq y \in P} \frac{\mathrm{dist}_T(x, y)}{\|x - y\|}$$

是 ≥ 1的量，越小越好

Tree Embedding额外要求：2-HST

HST = hierarchically separated tree

一般要求这个树有更好的结构：

- 数据集P都在树的叶子上，且所有叶子高度相同（所以内部点都只是辅助点）
- 考虑任何一条从叶子到根的路径，边权依次乘以2

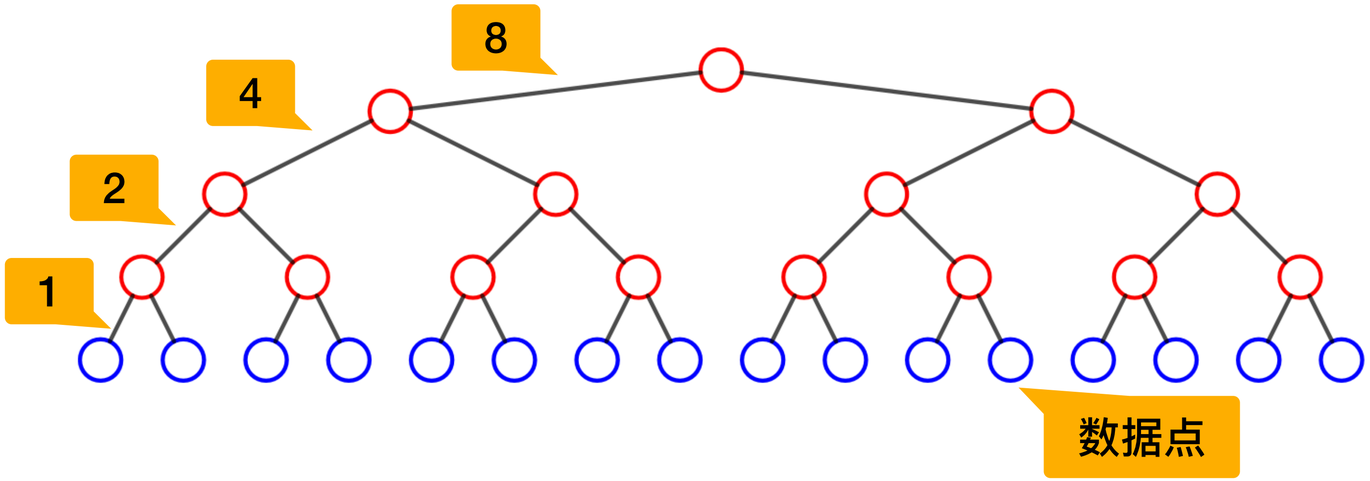

构造算法和结论

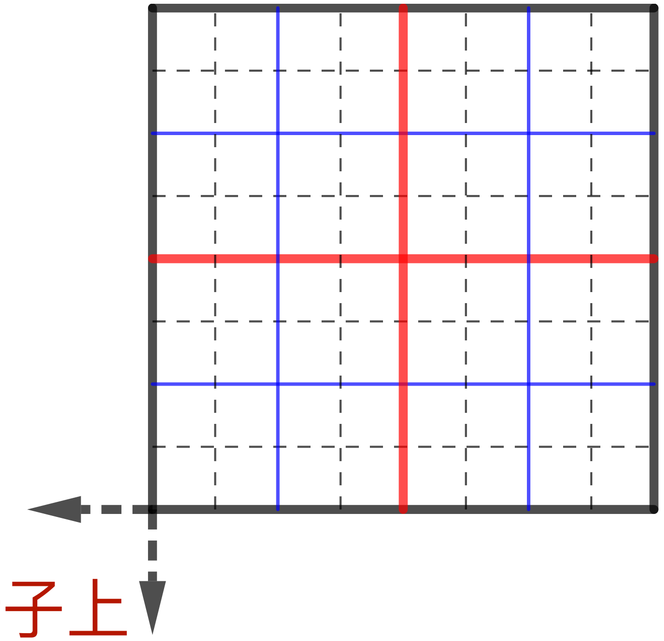

- 首先构造随机平移四分树
- 定义树T：每个□定义一个树节点，数据点都放在树的叶子上
  - 定义边：每个□连接到所有的直接孩子，赋予$\sqrt{d} \cdot 2^i$的权值，设□边长2^i
- 对于$x, y \in P$（都是树的叶子），距离$\mathrm{dist}_T(x, y)$就是树上的距离
- 结论：$\forall x, y \in P$，$\mathrm{dist}_T(x, y) \geq \|x - y\|$，$\mathbb{E}[\mathrm{dist}_T(x, y)] \leq O(dh) \cdot \|x - y\|$

下界是确定性的

上界是随机的

h是四分树的高度

关于距离保证

- $\mathbb{E}[\mathrm{dist}_T(x, y)] \leq O(dh) \cdot \|x - y\|$的保证只是数学期望
  - 因此如果考虑一个具体的T，很可能很多对点距离并不能达到该保证
- 可以证明，确定性/高概率保证一般而言是不可能的
  - 因此随机性对于tree embedding来说有本质的必要性
- 最优的distortion：（需要采用不同的算法）可以达到$\Theta(\log n)$的distortion

目前已知实现运行时间较差

  - Fakcharoenphol, Rao, Talwar: A tight bound on approximating arbitrary metrics by tree metrics. JCSS (2004)

扩展到其他设定

- 我们描述的算法可以在不读入具体数据集的情况下运行
  - 我们只是在$[\Delta]^d$上运行，可以把所有点都当叶子看待
  - 虽然实际数据集只是这些叶子的子集，但多余的叶子对于distortion并无影响
- 并且输出可以用查询的方式按需给出：
  - 给定一个数据点x，算法输出x从叶子到树根路径上所有树节点的ID
  - 应用：可以在数据流等空间受限设定下不显式建树，达到极小的空间占用

数据流算法

- 该tree embedding可以实现成数据流算法
  - 在数据流开始前采样平移量v
  - 之后对每个数据点x计算$x + v$
  - 可用$O(d)$空间时间计算所处的格子及其所有祖先

应用：高维欧氏最小生成树

复习定义

- 图的最小生成树（MST）：最小权的使所有点连通的子图
- 欧氏数据点集P的最小生成树：定义在P的欧氏图上的MST

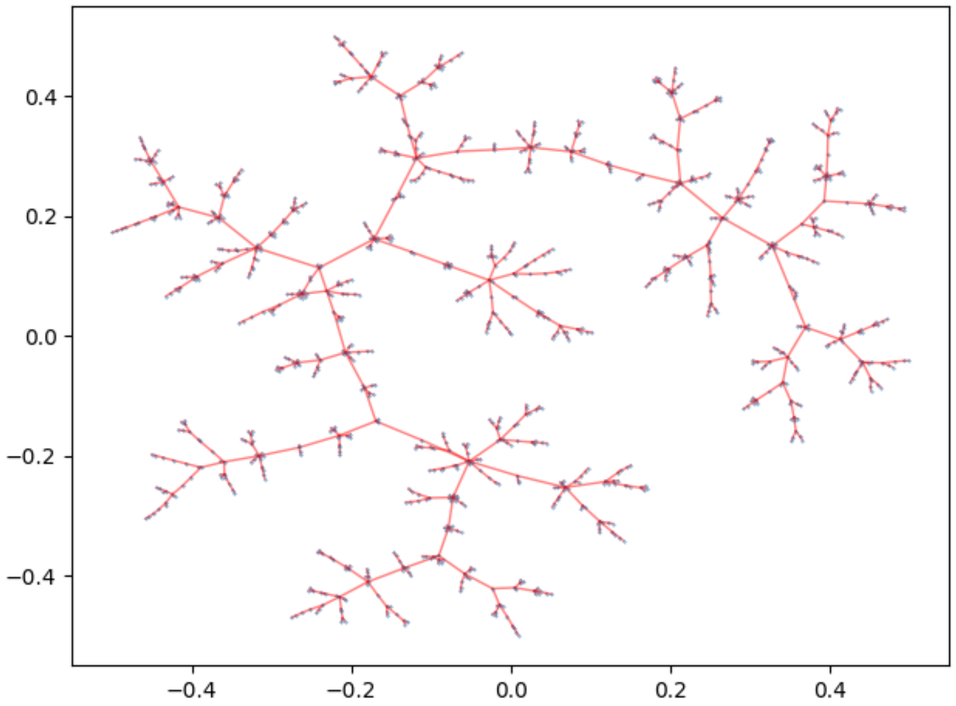

Tree Embedding近似高维MST

$O(dh)$近似比

- 结论：$\forall x, y \in P$，$\mathrm{dist}_T(x, y) \geq \|x - y\|$，$\mathbb{E}[\mathrm{dist}_T(x, y)] \leq O(dh) \cdot \|x - y\|$
- 高维MST算法：
  - 先建立T，然后在T上找（所有叶子的）MST，记为F_T，并设精确MST解为F^*

如何找F_T?

观察到$w(F_T) \leq \sum_{x,y \in F^*} \mathrm{dist}_T(x, y)$，所以

注意：F_T并不是P的欧氏图的子图，因此并不是P的生成树；
如何将F_T转化成P上的生成树而不增加代价?

$$\mathbb{E}_T[w(F_T)] \leq \mathbb{E}[\sum_{x,y \in F^*} \mathrm{dist}_T(x, y)] \leq O(dh) \sum_{x,y} \|x - y\| = O(dh) \cdot w(F^*)$$

其他应用：高维欧氏最小权匹配

- 最小权匹配问题：2n个$\mathbb{R}^d$上的点的最小欧氏权值的匹配
  - 匹配：n条边的集合，使得每个点参与到恰好一条边里
  - 权重：边$\{x, y\}$的权重是$\|x - y\|_2$，优化的是边权和
- 相关问题：二分/双色匹配（这里没有这条限制）

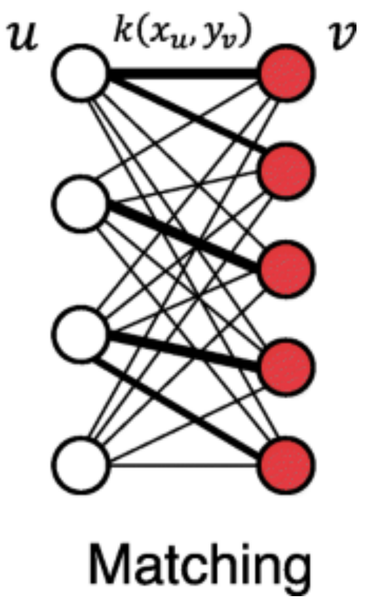

匹配与Tree Embedding

- 性质：在tree embedding上，子树内的点应该优先与同一子树的匹配
- 因此：仅当一个子树有奇数个后继时，需要将其跨子树匹配
  - 注意到：所有数据点都在叶子上，所以具体用哪个点匹配并不重要

- 如何实现成算法?

作业十五：Tree Embedding近似高维欧氏最小权匹配

- http://cssyb.openjudge.cn/25hw_15/
- Deadline: 5月9日
- 分值：2分

对比

- 劣势：近似比大$O(dh)$，尤其是达不到常数近似比
- 优势：
  - 因为每对点期望距离都能保持，因此广泛适用于目标函数是点距离和的问题

    最小生成树、聚类、匹配等各类问题；
    很多NP-hard问题在树上仍有有效算法
  - 树上算法性能较好，可解决问题多，有树算法就有欧氏空间近似算法、
  - 没有2^d，对于高维也适用
  - 可以扩展到数据流等设定

Tree Embedding分析

树上距离的表示、下界

x和y的树上距离：考虑最小的同时包含x, y的□

对一路上的边权求和

Fact: 若$\mathrm{LCA}(x, y)$的□边长2^i，那么树上距离是$2 \cdot \sqrt{d} \sum_{j=0}^{i} 2^j = \Theta(\sqrt{d} \cdot 2^i)$

Claim：$\mathrm{dist}_T(x, y) \geq \|x - y\|$

验证：设$\mathrm{LCA}(x, y)$的□边长2^i，那么$\|x - y\| \leq \sqrt{d} 2^i \leq \sum_{j=0}^{i} \sqrt{d} 2^j$

上界

验证： $\mathbb{E}[\mathrm{dist}_T(x,y)] \le dh \cdot \|x-y\|$

- 回忆：考虑x, y，设LCA(x,y)的□边长2^i，则

$$\mathrm{dist}_T(x,y) = 2 \cdot \sqrt{d} \sum_{j=0}^{i} 2^j = \Theta(\sqrt{d} \cdot 2^i)$$

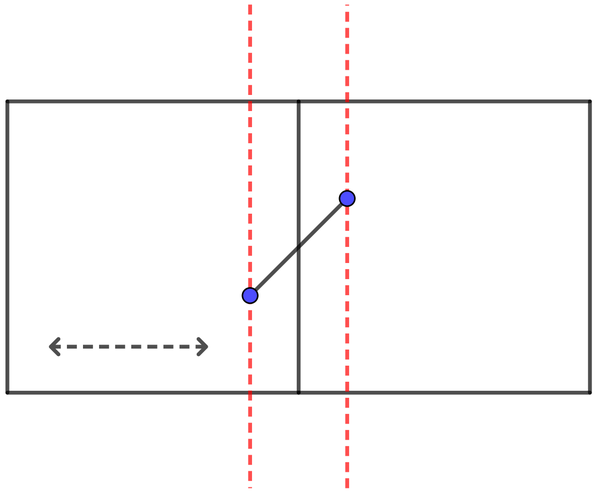

$$\begin{aligned}
\mathbb{E}[\mathrm{dist}_T(x,y)] &= \sum_{j=0}^{h} \Pr[\text{LCA is at } 2^j\text{-cube}] \cdot \Theta(\sqrt{d}2^j) \\
&\le \sum_{j=0}^{h} \Pr[x, y \text{ cut by } 2^{j+1}\text{-cubes}] \cdot O(\sqrt{d}2^j) \\
&\le O(hd) \cdot \|x-y\|
\end{aligned}$$

$$\boxed{\Pr[x, y \text{ are cut by } 2^i\text{-cubes}] \le \frac{\sqrt{d} \cdot \|x-y\|_2}{2^i}}$$

3. 随机平移四分树与 Range Query

Range Query问题

- 输入：在$\mathbb{R}^d$中的n个数据点集合P，参数$r > 0$
- 查询：给定$q \in \mathbb{R}^d$，估计$|B(q, r) \cap P|$的点数
- 一般而言： 查询要求估计$f(B(q, r) \cap P)$，其中f是composable函数
  - 称一个函数$f : 2^P \to \mathbb{R}$是composable的，若对任意的S及其划分$S_1, \ldots, S_t$ $f(S)$可以从$f(S_1), \ldots, f(S_t)$的值推出
  - 例如sum、max、min等

近似保证的定义、结论

- 引入记号$B_P(q,r) := B(q,r) \cap P$
- 这里考虑下面这种α-近似：实际返回的E满足$|B_P(q,r)| \le E \le |B_P(q,\alpha r)|$

$\alpha \ge 1$

即类似于近似近邻查询的要求，允许将αr内的点计入

- 我们介绍一种基于随机平移网格的算法

只需要网格，不需要四分树，
但必须随机平移

  - 查询达到$O(\alpha)$-近似、期望用时$O(2^{d/\alpha^{2/3}}\mathrm{poly}(d))$

主要针对大近似比

即牺牲精度改进指数上的依赖
选取足够大的α可以做到$d^{1.5}$-近似，$\mathrm{poly}(d)$时间
这个$\alpha^{2/3}$不一定是紧的，只是目前的分析能达到的界

算法

- 预处理：作边长$\ell = \alpha r/\sqrt{d}$的网格划分，并作随机平移（平移量每维在$[0,\ell]$）
- 找到所有使得$\square \cap B(q,r) \neq \varnothing$的$\square$，记这个$\square$形成的集合是$Q$
- 返回$\sum_{\square \in Q} |\square \cap P|$，即与$Q$中$\square$相交的数据点数，作为最终的估计

- 正确性：$B(q,r)$内的点都计入了；至多计入$B(q,(1+\alpha)r)$的点
- 复杂性：可以证明$|Q| \leq 2^{d/\alpha^{2/3}}\mathrm{poly}(d)$

作业十七：高维Range Query

- http://cssyb.openjudge.cn/25hw_17
- Deadline: 5月9日
- 分值：3分

- 标程参数选取：$\ell = 3r$，近似比最坏是$3\sqrt{d} + 1$

实现细节讨论

```
void search(int i, int id[]) {
    if (i == d) {
        if (dist(q, sq(id)) <= r)) Q.add(id);
        return;
    }
    id[i] = id_q[i]; search(i + 1, id);
    id[i] = id_q[i] - 3r; search(i + 1, iid);
    id[i] = id_q[i] + 3r; search(i + 1, id);
}
```

sq(id)即对应于id的□

id_q是q点所在□的id

- 以标程$\ell = 3r$的设定为例
- 关键步骤：求Q，即□$\cap B(q, r) \neq \varnothing$的□集合
- 暴力找Q：从q所在的□开始，探索相邻的格子
  - 设所有□都以最小坐标的顶点坐标作为ID
  - 从q所在□的ID向量的每一维，依次进行DFS搜索，穷举{不变，$+3r$，$-3r$}
- 保留到q距离在r内的□

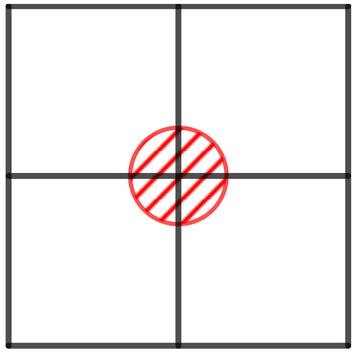

优化

```
void search(int i, int id[]) {
    if (i == d) {
        if (dist(q, sq(id)) <= r)) Q.add(id);
        return;
    }
    if (dist(q, sq(id) > r) return;
    id[i] = id_q[i]; search(i + 1, id);
    id[i] = id_q[i] - 3r; search(i + 1, iid);
    id[i] = id_q[i] + 3r; search(i + 1, id);
}
```

可选：用Trie实现Q

剪枝

- 完全DFS暴力搜索至少需要2^d
- 剪枝：让算法需要考虑的id数组至多有$O(|Q| \cdot d)$个
  - 设DFS运行到某个维度$i \in [d]$，并设目前穷举到的是id[]
  - 如果此时的sq(id)已经距离q大于r了，那后面$d-i$维不用继续考虑，可以剪枝
    - 原因：后面$d-i$维都不改变时已经距离大于r了，改变后距离只会更大
- 可选优化：Q需要实现id（即d维数组/字符串）的集合，可以考虑Trie

剪枝的效果

具体指相差3r（因为我们仅考虑算法产生的id）

- 考虑一个辅助图：每个id对应一个vertex，两个id连边当且仅当恰有一维不同
  - 我们的search算法可以看作是在该图上做DFS，起点就是查询点q的id
  - 因此每个vertex的degree是d
  - Q里面的点对应于一个连通分量，记作W
- 剪枝相当于：在DFS遇到连通分量W外面的第一个点时停止继续DFS
  - degree是d，所以最多额外扩展了d倍，也就是$d|Q|$