程序设计实习（实验班-2025春）
降维：PCA方法

授课教师：姜少峰
助教：管晏如、孔启皓、楼家宁、杨卓凡

Email: shaofeng.jiang@pku.edu.cn

PCA降维：
揭示数据维度间的隐含依赖关系

一个引例

	原神	Splatoon	PUBG Mobile	塞尔达传说
Alice	10	1	2	7
Bob	7	2	1	10
Carolyn	2	9	7	3
Dave	3	6	10	2

- 与线性回归不同：无label y，只是一些向量
- 有什么内在关系?
- 是否可能将这个4维数据以某种方式在2维平面展现出来，体现内在关系?

一种新的表达

	原神	Splatoon	PUBG Mobile	塞尔达传说
Alice	10	1	2	7
Bob	7	2	1	10
Carolyn	2	9	7	3
Dave	3	6	10	2

平均值向量

- $\bar{\mathbf{x}} = \frac{1}{4}(\mathbf{x}_1 + \ldots \mathbf{x}_4) = (5.5, 4.5, 5, 5.5)$
- 所有向量可以近似表示为$\mathbf{x}_i = \bar{\mathbf{x}} + a_i\mathbf{v}_1 + b_i\mathbf{v}_2$
  - $\mathbf{v}_1 = (3, -3, -3, 3), \ \mathbf{v}_2 = (1, -1, 1, -1)$
- A = (1, 1), B = (1, -1), C = (-1, -1), D = (-1, 1)

A代入得到$(9.5, 0.5, 3, 7.5)$，近似相等

利用新表达进行可视化

- $\mathbf{x}_i = \bar{\mathbf{x}} + a_i\mathbf{v}_1 + b_i\mathbf{v}_2$在这种表达中，$(a_i, b_i)$可以看作是新的“坐标”
- A = (1, 1), B = (1, -1), C = (-1, -1), D = (-1, 1)
- 若有更多的点，可根据相对ABCD的远近来定义类别/聚类

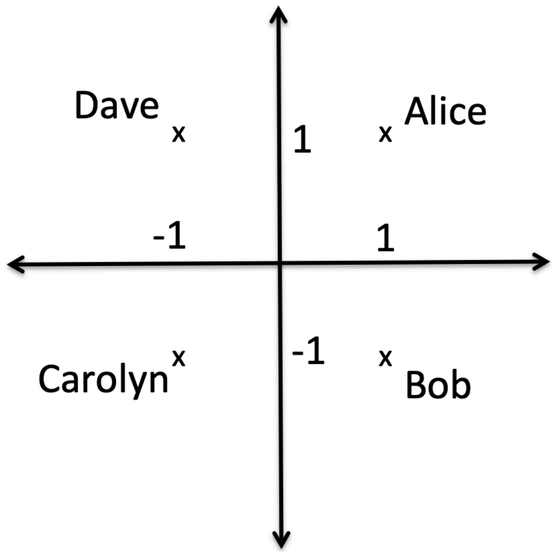

低维表达的意义

	原神	Splatoon	PUBG Mobile	塞尔达传说
Alice	10	1	2	7
Bob	7	2	1	10
Carolyn	2	9	7	3
Dave	3	6	10	2

- $\mathbf{x}_i = \bar{\mathbf{x}} + a_i\mathbf{v}_1 + b_i\mathbf{v}_2$在这种表达中，$(a_i, b_i)$可以看作是新的“坐标”
  - 那么$\mathbf{v}_1 = (3, -3, -3, 3)$，$\mathbf{v}_2 = (1, -1, 1, -1)$就是“坐标轴”/“基”
- 如何理解$\mathbf{v}_1$和$\mathbf{v}_2$?

	原神	Splatoon	PUBG Mobile	塞尔达传说
Alice	10	1	2	7
Bob	7	2	1	10
Carolyn	2	9	7	3
Dave	3	6	10	2

- $\mathbf{v}_1 = (3, -3, -3, 3)$，$\mathbf{v}_2 = (1, -1, 1, -1)$
  - 在$\mathbf{v}_1$中第1、4维度是正数，认为是“正相关”
  - 2、3维度是负数，认为他们之间“正相关”，但与1、4之间都是负相关
- 1、4都是动作游戏，2、3是射击，可将$\mathbf{v}_1$系数a_i看作某人喜欢动作游戏程度
- 对于$\mathbf{v}_2$：可看作喜欢手机游戏的程度，但$\mathbf{v}_2$绝对值较低，因此不如$\mathbf{v}_1$“显著”

PCA

中文 = 主成分

- $\mathbf{v}_1$和$\mathbf{v}_2$就是数据集所谓的top 2 principle components
- PCA就是系统性定义、寻找哪些是principle components

与JL的对比

- JL保欧氏距离，PCA一般没法保
- JL是data oblivious，而PCA正相反，找到的基是数据特殊内部结构的反映
- JL的m个随机高斯也可以理解成某种“基”，但没有任何实际意义
  - 而PCA的基经常都对应明显的实际意义
- PCA的target dimension即使等于1、2也是有意义的，而JL需要更高才能保距离

PCA定义

PCA：大体目标

- 输入：n个d维数据点$\mathbf{x}_1, \ldots, \mathbf{x}_n \in \mathbb{R}^d$
- 想找到m个d维“基”$\mathbf{v}_1, \ldots, \mathbf{v}_m \in \mathbb{R}^d$，使得每个$\vec{x}_i$可以用这些基近似表示

m类似JL的target dimension
一般$m \ll n$，甚至为了可视化，经常取$m = 2$

$$\forall 1 \leq i \leq n, \quad \mathbf{x}_i \approx \sum_{j=1}^{m} a_{ij}\mathbf{v}_j$$

所谓用“基”来表示，意思就是用基的线性组合来表示

- 刚刚的例子n = 4, d = 4, m = 2
- PCA的定义就是要规定怎样的基$\mathbf{v}_1, \ldots, \mathbf{v}_m$是“最佳近似”

通过规定某种目标函数

类似于linear regression，但……

linear regression要找$\mathbf{w}$使得$\mathbf{y}_i \approx \langle \mathbf{w}, \mathbf{x}_i \rangle$

刚刚提到的PCA的目标：$\mathbf{x}_i \approx \sum_{j=1}^{m} a_{ij}\mathbf{v}_j$

也是线性关系；如果$m = 1$那么就也是找一条拟合直线

都是用m维（低维）来近似，或者说“拟合”

- linear regression拟合的是x和y
- PCA拟合的是自身

必要的预处理

均值归0

严格来说不预处理也可以通过修改定义来解决，但那样引入了很多不必要的麻烦

- 对于PCA来说需要进行如下预处理才能良定义
- 均值$\bar{\mathbf{x}} = \frac{1}{n}\sum_{i=1}^{n}\mathbf{x}_i$需要是0：可先计算点集的$\bar{\mathbf{x}}$，然后更新$\mathbf{x}_i := \mathbf{x}_i - \bar{\mathbf{x}}$
  - 当找到m个“基”之后，可以再加上$\bar{\mathbf{x}}$平移回去

必要的预处理

去标度化

标准的PCA定义不是标度无关的

- 数据点的每一维可能代表不同的“单位”，这会干扰最终结果
  - 例如m = 1，那么最终结果就是一条“拟合”直线

直线是m = 1维的
xy面是m = 2维的...

  - 如果数据点在某个维度上进行了拉伸，那么这条线也会跟着改变

例如将单位从“千米”换成了“米”

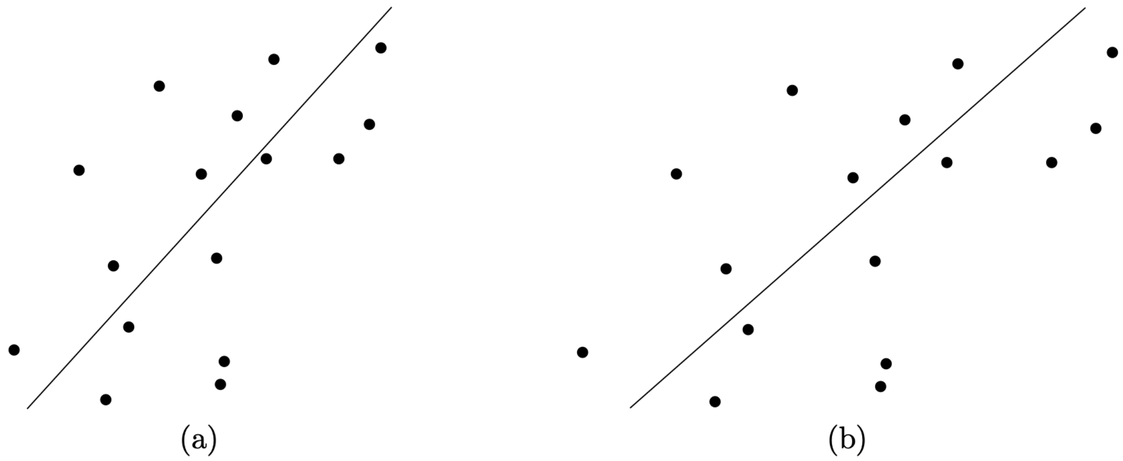

去标度：列/维度归一化

- 我们想要一个“标度”无关的结果，因此一般把每一维/列的ℓ_2范数归一化，即

$$\forall 1 \le i \le n, 1 \le j \le d, \quad \mathbf{x}_{ij} := \mathbf{x}_{ij} / \sqrt{\sum_{i'=1}^{n} \mathbf{x}_{i'j}^2}$$

例如：$\begin{bmatrix} 1 & 10 & 5 & 7 \\ 2 & 3 & 4 & 8 \\ 2 & 5 & 1 & 9 \end{bmatrix}$ 第一列范数是3，归一化后是(1/3,2/3,2/3)；其他列可类似操作

目标函数

- 先考虑target dimension $m = 1$的情况，PCA要找一个最佳“拟合”数据的直线

直观上类似linear regression

$$\arg\min_{\mathbf{v}:\|\mathbf{v}\|=1} \frac{1}{n}\sum_{i=1}^{n} (\text{dist between } \mathbf{x} \text{ and line spanned by } \mathbf{v})^2$$

要找一个方向$\mathbf{v}$

line spanned by $\mathbf{v}$就是以$\mathbf{v}$为方向过原点的直线

即点到直线距离的平方和

目标函数等价于：最大化variance

- 勾股定理：对任何$\mathbf{x}$和单位向量$\mathbf{w}$有$\mathrm{dist}(\mathbf{x}, \mathrm{line}(\mathbf{w}))^2 + \langle \mathbf{x}, \mathbf{w} \rangle^2 = \|\mathbf{x}\|^2$

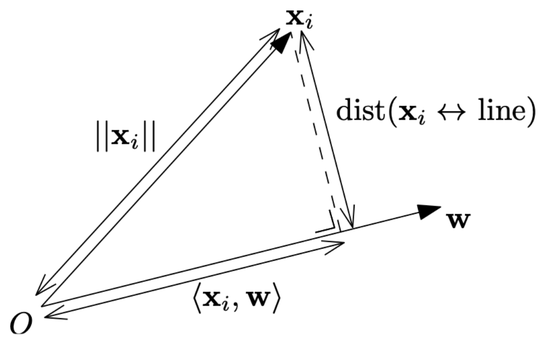

- 因此原目标min点到直线距离平方，就是max投影的长度平方，也就是等价于

$$\arg\max_{\mathbf{v}:\|\mathbf{v}\|_2=1} \frac{1}{n} \sum_{i=1}^{n} \langle \mathbf{x}_i, \mathbf{v} \rangle^2$$

这个求和叫做点集投影的variance

- 假若数据有两团/cluster，那么我们想投影到一条线使得这种性质得以保留
  - bad line的问题是投影后在线上来看两团点都混合在一起了
  - good line就还是能分开

对应于最大化variance！

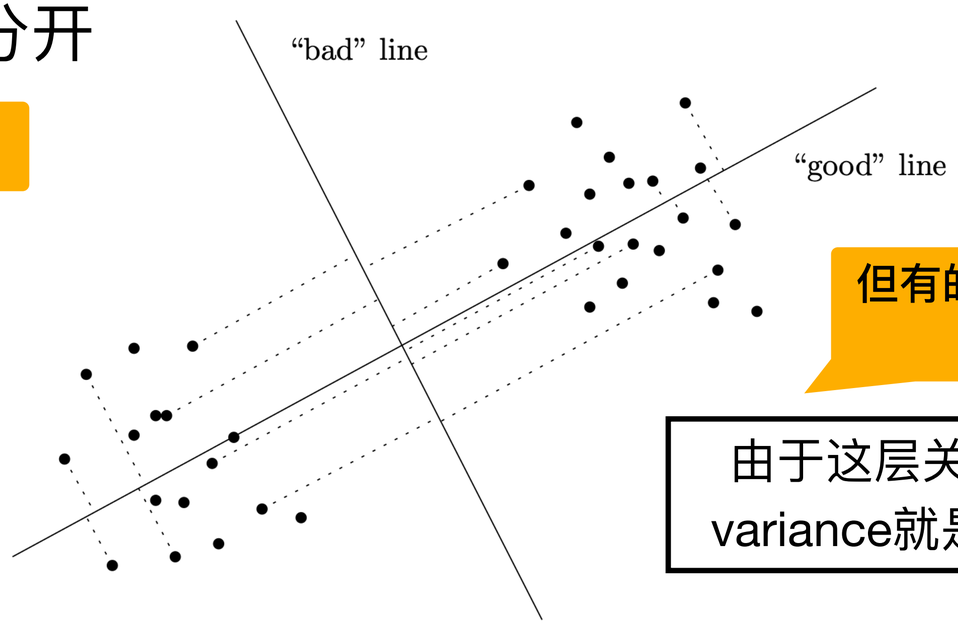

但有的数据中这种variance反而不应该保留，因此PCA可能不适用

由于这层关系，PCA基本上就是认为这种variance就是有用信息，应该尽量得以保留

一般的target dimension m

回忆$m = 1$的情况：

投影长度

$$\arg\max_{\mathbf{v}:\|\mathbf{v}\|_2=1} \frac{1}{n}\sum_{i=1}^{n} \langle \mathbf{x}_i, v\rangle^2$$

一个自然的扩展方法：

$$\underset{m\text{-dim subspace } S}{\arg\min} \quad \frac{1}{n}\sum_{i=1}^{n} (\text{length of the projection of } \mathbf{x}_i \text{ on } S)^2$$

可以转化成一个更好“操作”的定义方法

Subspace与Orthonormal Basis

一个m维的subspace可以等价地用m个orthonormal向量的span来表示

- 一组向量$\mathbf{v}_1, \ldots, \mathbf{v}_m$是orthonormal的，若$\|\mathbf{v}_i\| = 1$且$\langle \mathbf{v}_i, \mathbf{v}_j \rangle = 0$ （对$i \neq j$）

normal

orthogonal

$$\mathrm{span}(\mathbf{v}_1, \ldots, \mathbf{v}_m) := \left\{ \sum_{i=1}^{m} \lambda_i \mathbf{v}_i : \lambda_i \in \mathbb{R} \right\}$$

span就是这些向量的所有线性组合

重要性质：$\mathbf{x}$在$\mathrm{span}(\mathbf{v}_1, \ldots, \mathbf{v}_m)$上的投影长度（的平方）等于$\sum_{i=1}^{m} \langle \mathbf{x}, \mathbf{v}_i \rangle^2$

PCA目标函数：最终版本

简化表示

假设均值0且每列归一

输入$\mathbf{x}_1, \ldots, \mathbf{x}_n \in \mathbb{R}^d$，求orthonormal的$m$个向量$\mathbf{v}_1, \ldots, \mathbf{v}_m \in \mathbb{R}^d$，最大化

$$\text{Maximize} \quad \frac{1}{n} \sum_{i=1}^{n} \underbrace{\sum_{j=1}^{m} \langle \mathbf{x}_i, \mathbf{v}_j \rangle^2}_{\text{squared proj. length}}$$

最优的这m个向量叫做$\mathbf{x}_1, \ldots, \mathbf{x}_n$的前$m$个principle components

PCA应用

一般框架

- 设置一个m，然后求出top m principle components $\mathbf{v}_1, \ldots, \mathbf{v}_m \in \mathbb{R}^d$
- 对于某数据点$\mathbf{x} \in \mathbb{R}^d$，$\mathbf{v}_i$-坐标是$\langle \mathbf{x}, \mathbf{v}_i \rangle$，即在$\mathbf{v}_i$上的投影
  - 正数、负数代表什么？绝对值大小代表什么？
- $(\langle \mathbf{x}, \mathbf{v}_1 \rangle, \ldots, \langle \mathbf{x}, \mathbf{v}_m \rangle)$就是$\mathbf{x}$新的$m$维坐标表示
  - 如果m取比较小，可以plot出来

而且我们对任何数据点$\mathbf{x} \approx \sum_{j=1}^{m} \langle \mathbf{x}, \mathbf{v}_j \rangle \mathbf{v}_j$

- 考虑top principle component $\mathbf{v}_1$，如何给$\mathbf{v}_1$一个“物理意义”/“直观解释”?
  - 一般来说，可以看在$\mathbf{v}_1$上最大和最小的坐标及其“附近”的点
  - 这两组点之间的不同点，以及这两组点内部的相同点，可以帮助解释$\mathbf{v}_1$
- $\mathbf{v}_2$一般来说也都能找到一些“物理意义”

PCA应用：基因与地理的联系

Novembre et al., Nature 2008

- 数据集：1387个来自欧洲各地的欧洲人的基因数据
  - 每个数据点是一个200000维的向量，这些维度是基因信息，对基因突变敏感
  - 例如，可能在某个维度上90%人是A，其余10%是C
- 论文采用了$m = 2$的PCA来进行可视化

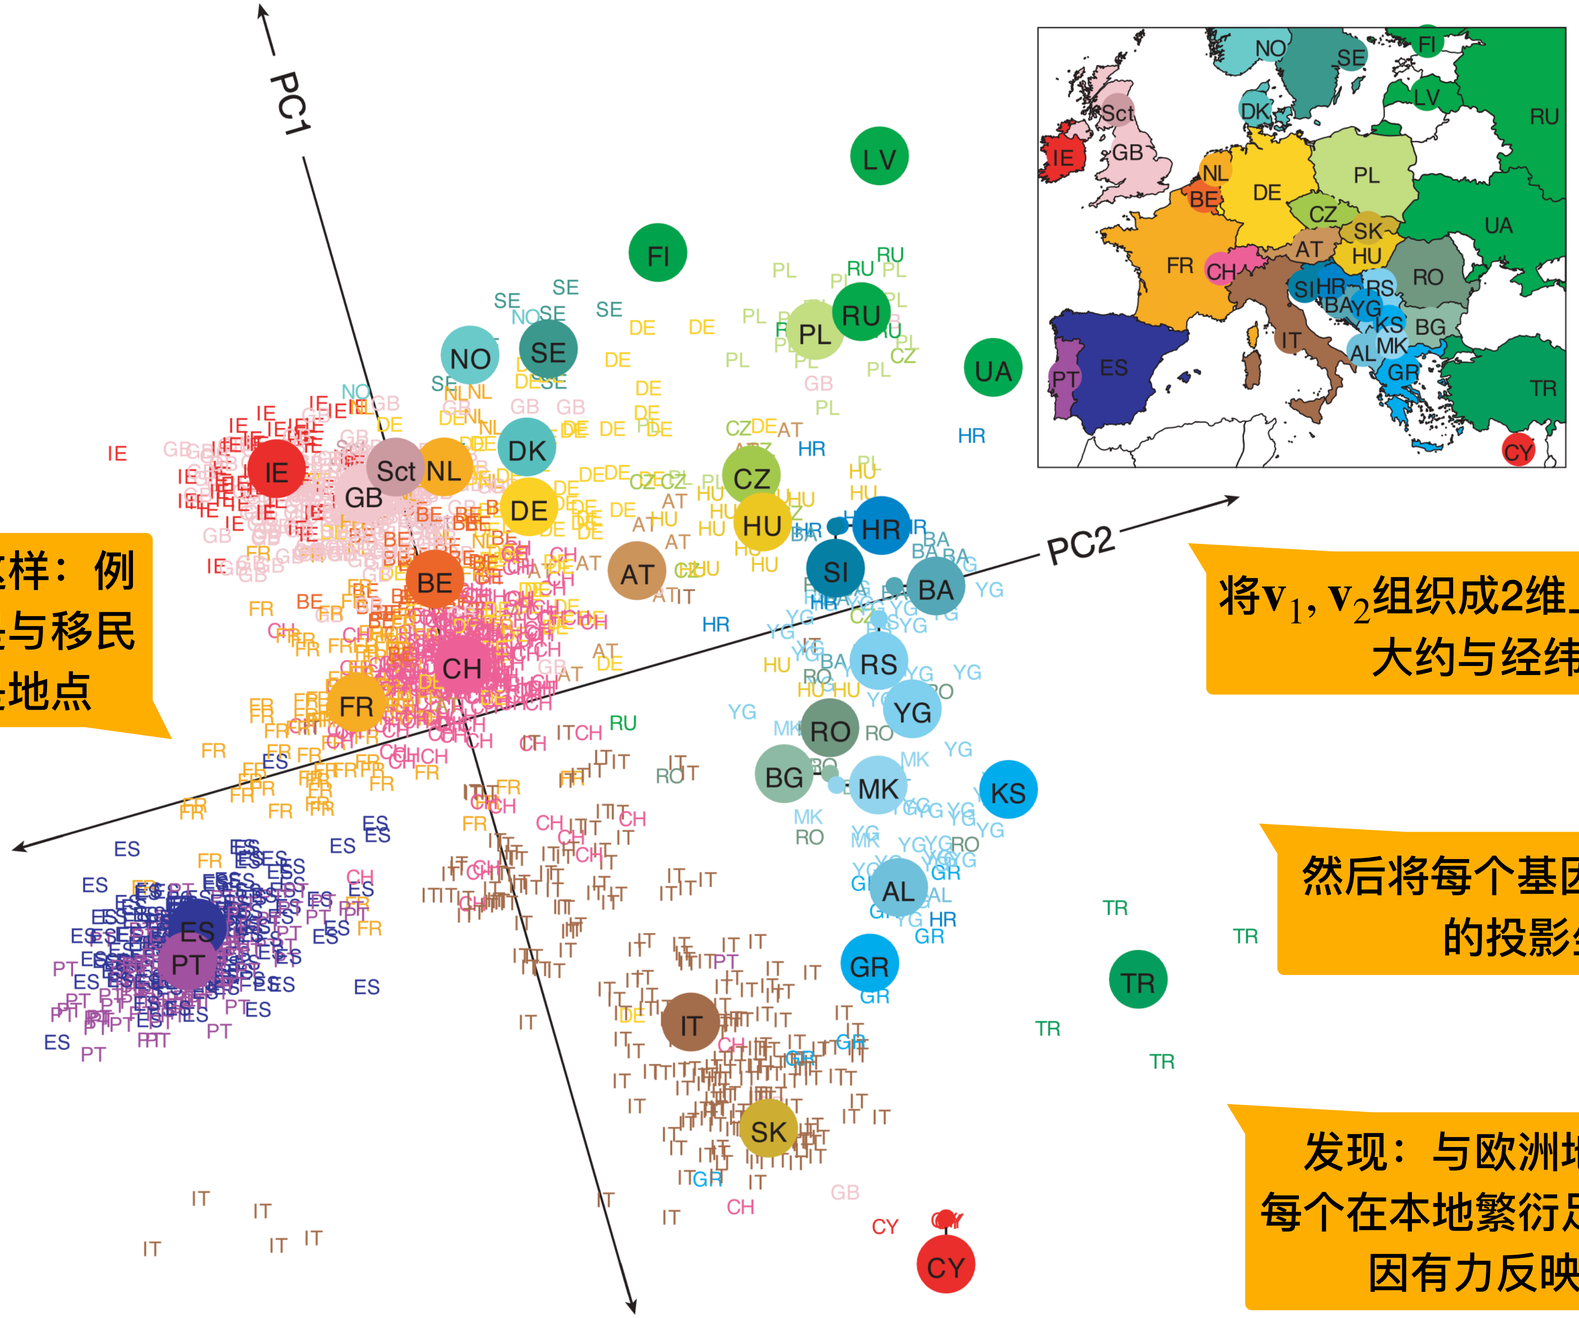

在别的地区未必会是这样：例如在美国基因大概率是与移民时间有关系，而不是地点

将$\mathbf{v}_1, \mathbf{v}_2$组织成2维上的垂直向量，大约与经纬线平行

然后将每个基因数据按照$\mathbf{v}_1, \mathbf{v}_2$上的投影坐标画出来

发现：与欧洲地理高度重合！每个在本地繁衍足够时间的人的基因有力反映了地理位置

PCA应用：Eigenface

- 用PCA来做人脸建模和识别

数据集示例

男性平均值

- 数据集：256 x 256的正面标准人脸数据
  - 展开成65536维的向量，每个维度代表像素值
  - 按照PCA预处理规则，均值归零

减去平均值后的数据

图像“压缩”/“降维”

- 使用PCA，$m \approx 100$，远低于65535，可非常精确地表达这些图像
- 有趣的事实：每个principle component可视化成图像，一般代表某种特征

戴不戴眼镜；留不留胡子etc

这种principle component又叫做eigenface

- 逐渐增大m的效果：从平均脸到具体数据

我们将要讲到principle components是eigenvector

可以在m维上用nearest neighbor search等方法做人脸查询

PCA的局限性?

有时每维归一可能是不够的，也许需要专门设计如何scaling

不抗噪声：一个放在无穷远的单点可让解失去意义

PCA类似linear regression，只能找到数据的线性特征

一般只有前几个principle components有物理意义

- 尤其是当数据中没有明显的、多个“orthogonal”意义的时候
- 如欧洲人基因与地理关系的应用中第三个principle component?

非线性、但只有1维/自由度

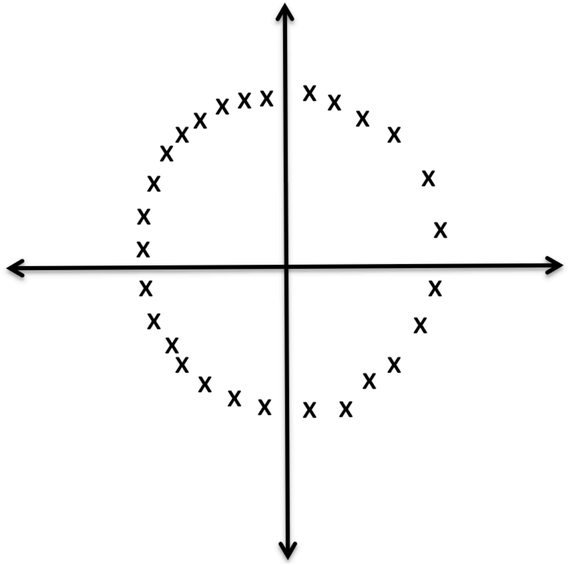

PCA求解：公式

考虑$m = 1$

输入$\mathbf{x}_1, \ldots, \mathbf{x}_n \in \mathbb{R}^d$，求orthonormal的$m$个向量$\mathbf{v}_1, \ldots, \mathbf{v}_m \in \mathbb{R}^d$，最大化

$$\frac{1}{n} \sum_{i=1}^{n} \sum_{j=1}^{m} \langle \mathbf{x}_i, \mathbf{v}_j \rangle^2$$

$m = 1$的情况：$\arg \max_{\mathbf{v}: \|\mathbf{v}\|=1} \frac{1}{n} \sum_{i=1}^{n} \langle \mathbf{x}_i, \mathbf{v} \rangle^2$

重写成矩阵形式

目标函数：$\arg\max_{\mathbf{v}:\|\mathbf{v}\|=1} \frac{1}{n}\sum_{i=1}^{n}\langle \mathbf{x}_i, \mathbf{v}\rangle^2$

设$\mathbf{X} \in \mathbb{R}^{n\times d}$为将每个$\mathbf{x}_i$作为一行的矩阵，那么 $\mathbf{X}\mathbf{v} = \begin{bmatrix} \langle \mathbf{x}_1, \mathbf{v}\rangle \\ \vdots \\ \langle \mathbf{x}_n, \mathbf{v}\rangle \end{bmatrix}$

所以目标函数中 $\sum_{i=1}^{n}\langle \mathbf{x}_i, \mathbf{v}\rangle^2 = \|\mathbf{X}\mathbf{v}\|^2 = (\mathbf{X}\mathbf{v})^\top\mathbf{X}\mathbf{v} = \mathbf{v}^\top\mathbf{X}^\top\mathbf{X}\mathbf{v}$

设$\mathbf{A} = \mathbf{X}^\top\mathbf{X}$，则目标等价于$\arg\max_{\mathbf{v}:\|\mathbf{v}\|=1} \mathbf{v}^\top\mathbf{A}\mathbf{v}$

$\mathbf{A} = \mathbf{X}^\top\mathbf{X}$的意义

covariance matrix

$\mathbf{v}^\top\mathbf{A}\mathbf{v}$又叫做“二次型”
因此这个问题又叫最大化二次型

设$\mathbf{A} = \mathbf{X}^\top\mathbf{X}$，则目标等价于$\arg\max_{\mathbf{v}:\|\mathbf{v}\|=1} \mathbf{v}^\top\mathbf{A}\mathbf{v}$

- $\mathbf{A}_{ij}$其实是$\mathbf{X}$的第i列与第j列的点乘
  - 意义：例如$\mathbf{X}$的一列/维代表某个单词在某个文档是否出现（值为0/1）
  - 那么第i列与第j列的点乘就是词i与词j共同出现的文档个数

描述correlation

- $\mathbf{A} = \mathbf{X}^\top\mathbf{X}$叫做covariance matrix

如何求解特殊情况：A是对角阵

特例：$\mathbf{A} = \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_d \end{bmatrix}$，设$\lambda_1 \geq \ldots \geq \lambda_d \geq 0$

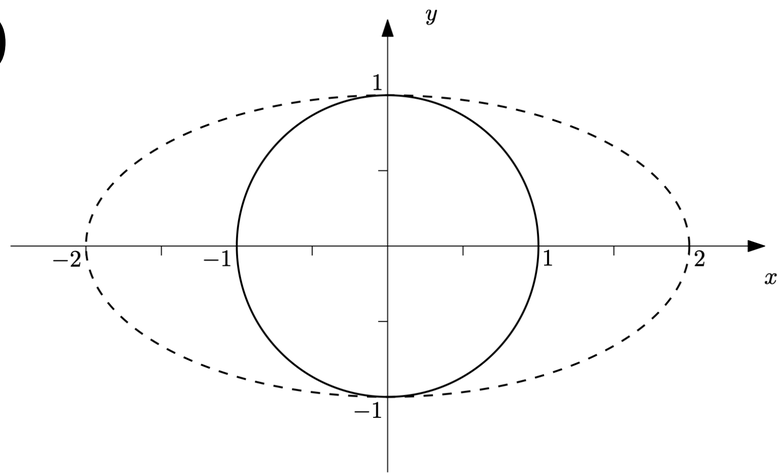

左乘对角阵就是拉伸每个维度，例如$\begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = 2x + y$

对角阵 = 伸缩变换

对角阵的Principle Component

$$\mathbf{v}^\top(\mathbf{A}\mathbf{v}) = [v_1, \ldots, v_d] \cdot \begin{bmatrix} \lambda_1 v_1 \\ \vdots \\ \lambda_d v_n \end{bmatrix} = \sum_{i=1}^{d} \lambda_i v_i^2$$

取什么$\mathbf{v}$可以最大化?

直观理解：取“拉伸”最大的方向，即$\mathbf{v} = \mathbf{e}_1 = (1,\ldots,0)$

代数上，$\sum_{i=1}^{d} \lambda_i v_i^2$是所有$\lambda_i$的一个加权平均，那么自然应该把权重都放在最大值$\lambda_1$

更进一步：考虑一种“带方向”的伸缩

将圆沿着45度方向为轴拉伸2倍

- 例如右边的变换：

$$\begin{bmatrix} \frac{3}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{3}{2} \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} \cdot \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$

最后旋转45度回来　再拉伸2倍　先顺时针旋转45度

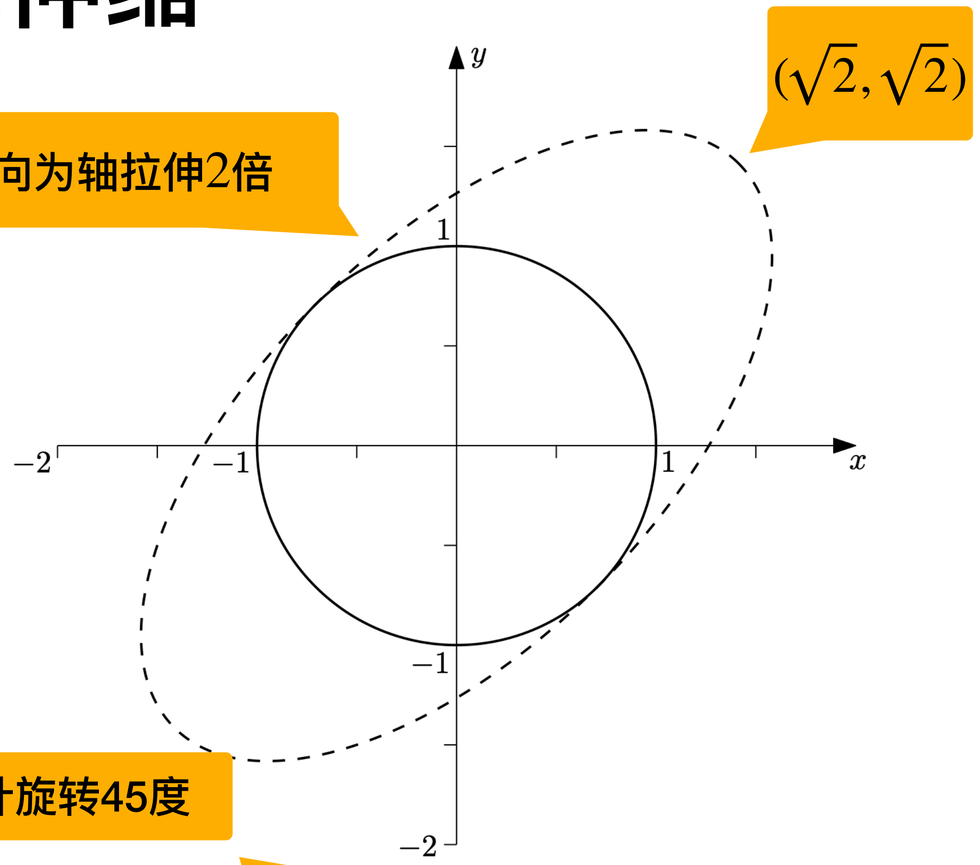

这其实是“伪装”的伸缩：
旋转之后伸缩又再转回去

这个旋转矩阵 $\begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$ 一般而言是一个orthogonal matrix

Orthogonal Matrix

即一组“基”

定义：$\mathbf{Q}$是orthogonal matrix，若$\mathbf{Q}$是一个方阵且所有列是orthonormal的

性质：

$\mathbf{Q}^\top\mathbf{Q}$的第$i$行$j$列是$\mathbf{Q}$的$i$列与$j$列的点积
然后利用列orthonormal的性质

- $\mathbf{Q}^\top\mathbf{Q} = \mathbf{I}$：说明$\mathbf{Q}$的逆矩阵就是$\mathbf{Q}^\top$

  这同时也推出了$\mathbf{Q}$的行也是orthonormal的

- 不改变模长：对任何$\mathbf{v}$有$\|\mathbf{Q}\mathbf{v}\| = \|\mathbf{v}\|$
  - 因为：$\|\mathbf{Q}\mathbf{v}\|^2 = (\mathbf{Q}\mathbf{v})^\top(\mathbf{Q}\mathbf{v}) = \mathbf{v}^\top\mathbf{Q}^\top\mathbf{Q}\mathbf{v} = \mathbf{v}^\top\mathbf{v} = \|\mathbf{v}\|^2$
- $\mathbf{Q}$是旋转矩阵：$\mathbf{Q}\mathbf{x}$是$\mathbf{x}$在$\mathbf{Q}$定义的基上投影长度向量，即旋转后的“坐标”

“伪装”的对角阵A：$\mathbf{A} = \mathbf{Q}\mathbf{D}\mathbf{Q}^\top$

- 考虑$\mathbf{A} = \mathbf{Q}\mathbf{D}\mathbf{Q}^\top$，其中$\mathbf{Q}$是orthogonal matrix，$\mathbf{D}$是对角阵

另一个直觉：带方向的伸缩

- 这种$\mathbf{A}$是“伪装”的对角阵：先用$\mathbf{Q}^\top$做旋转，用$\mathbf{D}$伸缩，然后$\mathbf{Q}$转回去
- 这种$\mathbf{A}$下最优解是多少?

设$\mathbf{A} = \mathbf{X}^\top\mathbf{X}$，则目标等价于$\arg\max_{\mathbf{v}:\|\mathbf{v}\|=1} \mathbf{v}^\top\mathbf{A}\mathbf{v}$

- 依然应该取拉伸最大的方向，也就是λ_1“对应”的方向

这就是$\mathbf{Q}$的第一列

- 单在$\mathbf{D}$上看应是$\mathbf{v} = \mathbf{e}_1$，但$(\mathbf{v}^\top\mathbf{Q})\mathbf{D}(\mathbf{Q}^\top\mathbf{v})$变换后应取$\mathbf{Q}^\top\mathbf{v} = \mathbf{e}_1$即$\mathbf{v} = \mathbf{Q}\mathbf{e}_1$

将$\mathbf{Q}^\top\mathbf{v}$看作一个整体，对应$\mathbf{v}$的地位

为什么取Q的第一列：代数解释

- 考虑$\mathbf{A} = \mathbf{Q}\mathbf{D}\mathbf{Q}^\top$，其中$\mathbf{Q}$是orthogonal matrix，$\mathbf{D}$是对角阵

设$\mathbf{A} = \mathbf{X}^\top\mathbf{X}$，则目标等价于$\arg\max_{\mathbf{v}:\|\mathbf{v}\|=1} \mathbf{v}^\top\mathbf{A}\mathbf{v}$

- 代数上，注意到$(\mathbf{v}^\top\mathbf{Q})\mathbf{D}(\mathbf{Q}^\top\mathbf{v})$依然是对$\lambda_i$的加权平均

注意到$\mathbf{Q}^\top\mathbf{v}$是单位向量，因此是加权“平均”

- 如果代入$\mathbf{v} = \mathbf{Q}\mathbf{e}_1$，得到

$$(\mathbf{v}^\top\mathbf{Q})\mathbf{D}(\mathbf{Q}^\top\mathbf{v}) = (\mathbf{e}_1^\top\mathbf{Q}^\top\mathbf{Q})\mathbf{D}(\mathbf{Q}^\top\mathbf{Q}\mathbf{e}_1) = \mathbf{e}_1^\top\mathbf{D}\mathbf{e}_1 = \lambda_1$$

达到了加权平均的最大可能值，因此是最优的

一般矩阵$\mathbf{A} = \mathbf{X}^\top\mathbf{X}$?

- 事实上我们已经解决了一般情况：
  - 因为$\mathbf{A} = \mathbf{X}^\top\mathbf{X}$必可写成$\mathbf{QDQ}^\top$，且$\mathbf{D}$的每个元素确实都非负

    叫做eigendecomposition
  - 这个命题的具体证明一般在性代数课会涉及
- 因此我们得到了：
  - 对于target dimension $m = 1$，principle component是$\mathbf{Q}$的第一列
  - 这里$\mathbf{Q}$就是$\mathbf{X}^\top\mathbf{X}$的eigendecomposition的$\mathbf{Q}$

一般的m?

可以这样考虑：先得到$\mathbf{Q}$第一列当作top principle component，对应的是得到λ_1的方向；再看与它垂直的方向中得到λ_2的就是$\mathbf{Q}$第二列

- 可以用类似的方法得到：top m principle就是$\mathbf{Q}$的前m列
  - 假定$\mathbf{X}^\top\mathbf{X} = \mathbf{Q}\mathbf{D}\mathbf{Q}^\top$中$\mathbf{D}$是按照从大到小排列的（因此$\mathbf{Q}$的列也据此排列）
  - 可以看到，这m个向量确实是orthonormal的

与eigenvalue/eigenvector的联系

- 回忆什么是特征值/特征向量（eigenvalue/eigenvector）
  - 对矩阵$\mathbf{A}$，满足$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$的$\mathbf{v}$叫eigenvector，$\lambda$叫eigenvalue
- 在$\mathbf{A} = \mathbf{Q}\mathbf{D}\mathbf{Q}^\top$中，$\mathbf{Q}$的每一列$\mathbf{Q}\mathbf{e}_i$和$\mathbf{D}_{ii}$分别是第$i$个eigenvector和eigenvalue
  - 因为：$\mathbf{A}\mathbf{Q}\mathbf{e}_i = \mathbf{Q}\mathbf{D}\mathbf{e}_i = \lambda_i\mathbf{Q}\mathbf{e}_i$

按特征值从大到小排列的top m

因此PCA等价于：计算$\mathbf{X}^\top\mathbf{X}$的top m eigenvectors

一种常见的PCA的“定义”

关于PCA的“唯一”性

- PCA“基本上”是唯一的
- 首先，$\mathbf{X}^\top\mathbf{X} = \mathbf{Q}\mathbf{D}\mathbf{Q}^\top$这个分解中，若$\mathbf{D}$从大到小排列，则$\mathbf{D}$可证是唯一的
- 如果$\mathbf{D}$的值都不相等，那么$\mathbf{Q}$也是“唯一”的
- 如果有相等的：考虑一段连续ℓ个相等的$\mathbf{D}$值
  - 对应的$\mathbf{Q}$的ℓ列构成一个ℓ维子空间
  - 任何该子空间的ℓ个orthonormal vectors都可选成对应principle components

事实上每个列向量的+/-都是可能的，但对PCA来说principle component的符号不重要，重要的是张成的subspace/直线

PCA求解：快速近似算法

求解PCA的算法

- 大体有两类

复杂度较高，基本上是3次方时间，但可以计算出所有principle components

- 精确求解：注意到所有的PC都是$\mathbf{A} = \mathbf{X}^\top\mathbf{X}$的特征向量
  - 可以在$O(nd^2)$时间求出所有PC，也就是求出$\mathbf{QDQ}^\top$

这些算法必然是数值（近似）算法，因为求$\mathbf{D}$对应于求解特征多项式的所有根，而五次几以上多项式方程无求根公式

X是n x d的

- 近似求（最大）principle component
  - Power iteration：线性时间

$\mathrm{nnz}(\mathbf{X})$

近似求Top Principle Component: Power Iteration

算法设计思路

- 回忆：$\mathbf{A} = \mathbf{X}^\top\mathbf{X} = \mathbf{QDQ}^\top$本质上是将单位球映射到椭球
  - 椭球的最长轴就对应top principle component

$\mathbf{Qe}_1$

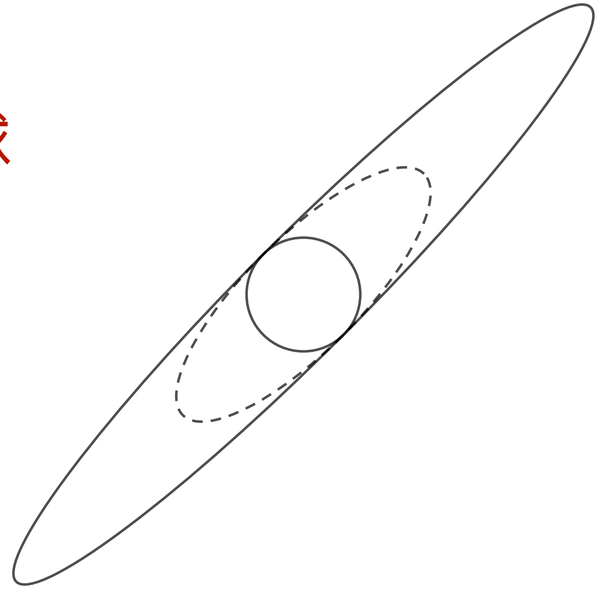

- 任取一个向量$\mathbf{u}$，只要不与$\mathbf{Qe}_1$垂直，那么反复应用$\mathbf{A}$后：
  - 将在$\mathbf{Qe}_1$方向反复被拉伸
  - 若假设最长轴确实比其他轴长，则最后$\mathbf{u}$会非常贴近于$\mathbf{Qe}_1$的方向

如果看椭球，则会在$\mathbf{Qe}_1$上拉的非常长，总体非常扁

算法

输入： $\mathbf{A} = \mathbf{X}^\top \mathbf{X}$

可以每一维独立$\mathcal{N}(0,1)$后归一化生成

选取一个随机方向向量$\mathbf{u}_0$

For $i = 1,2,\ldots$

$\mathbf{u}_i := \mathbf{A}^i \mathbf{u}_0$

根据实际情况设定“$\approx$”的标准

如果$\mathbf{u}_i/\|\mathbf{u}_i\| \approx \mathbf{u}_{i-1}/\|\mathbf{u}_{\mathbf{i-1}}\|$则停止并返回$\mathbf{u}_i/\|\mathbf{u}_i\|$

实现细节

复杂度nnz($\mathbf{X}$)

- 计算$\mathbf{A}u = \mathbf{X}^\top\mathbf{X}\mathbf{u}$时要注意顺序，先算$\mathbf{X}\mathbf{u}$而不是$\mathbf{X}^\top\mathbf{X}$
- $\mathbf{u}_i := \mathbf{A}^i\mathbf{u}_0$也不要每个$i$重新计算
- 利用递推式$\mathbf{u}_i = \mathbf{A}\mathbf{u}_{i-1} = \mathbf{X}^\top\mathbf{X}\mathbf{u}_{i-1}$

类似地，$\mathbf{A}^i\mathbf{u}_0$要利用$\mathbf{X}^\top\mathbf{X}u_{i-1}$从右往左计算，否则会从nnz($\mathbf{X}$)劣化成$nd^2$复杂性

作业二十：利用Power Iteration求Top PC

- http://cssyb.openjudge.cn/25hw20/
- 分值：2分；截止日期：6月4日

Power Iteration的保证

结论：设$\mathbf{v}_1$是top PC，则对于任何$t \geq 1$，随机$\mathbf{u}_0$有常数概率使得

注意只能保证绝对值，
但对于找PC足够

$$|\langle \mathbf{u}_t, \mathbf{v}_1 \rangle| \geq 1 - O(\sqrt{d})\left(\frac{\lambda_2}{\lambda_1}\right)^t$$

λ_1/λ_2叫做spectral gap
实际数据经常gap是>1的常数

$|\langle \mathbf{u}_t, \mathbf{v}_1 \rangle|$衡量了算法输出与$\mathbf{v}_1$间的误差：
如果等于1就没误差，越接近1与$\mathbf{v}_1$方向越接近

假设结论成立，那么要达到$1-\epsilon$误差，只需要$t = O\left(\frac{\log(d/\epsilon)}{\log(\lambda_1/\lambda_2)}\right)$

算法分析

- 先考虑一下$\mathbf{A}^i$是什么

$\mathbf{Q}^\top\mathbf{Q} = \mathbf{I}$

- $\mathbf{A}^i = (\mathbf{QDQ}^\top)^i = (\mathbf{QD}(\mathbf{Q}^\top\mathbf{Q})\mathbf{DQ}^\top)(\mathbf{QDQ}^\top)^{i-2} = \mathbf{QD}^2\mathbf{Q}^\top(\mathbf{QDQ}^\top)^{i-2}$
- 继续迭代下去，可以得到$\mathbf{A}^i = \mathbf{QD}^i\mathbf{Q}^\top$

所以$\mathbf{A}^i$将所有eigenvalue做了i次幂

如果λ_1, λ_2有个gap，例如$\lambda_1 > 2\lambda_2$，
则gap会迅速变大

证明

随机的初始值$\mathbf{u}_0$在$\mathbf{v}_1$上已经有“足够”大的投影

orthonormal，可以看成一组基

设$\mathbf{Q}$的列是$\mathbf{v}_1, \ldots, \mathbf{v}_d$，这些也是$\mathbf{X}^\top\mathbf{X} = \mathbf{QDQ}^\top$的eigenvectors

将随机向量$\mathbf{u}_0$表成$\mathbf{u}_0 = \sum_{i=1}^{d} a_i \mathbf{v}_i = \sum_{i=1}^{d} \langle \mathbf{u}_0, \mathbf{v}_i \rangle \mathbf{v}_i$

则常数概率有$|a_1| = |\langle \mathbf{u_0}, \mathbf{v_1} \rangle| \geq \Omega(1/\sqrt{d})$

为什么常数概率 $|a_1| = |\langle \mathbf{u_0}, \mathbf{v_1} \rangle| \geq \Omega(1/\sqrt{d})$?

$\mathbf{u}_0$是每维$\mathcal{N}(0,1)$再归一化得到的；先不归一化，考虑每维都是$\mathcal{N}(0,1)$的$\mathbf{u}'$

- 可得：$\langle \mathbf{u}', \mathbf{v}_1 \rangle$依然是一个$\mathcal{N}(0,1)$

根据正态分布，$|\langle \mathbf{u}', \mathbf{v}_1 \rangle| \geq 1$概率> 30%

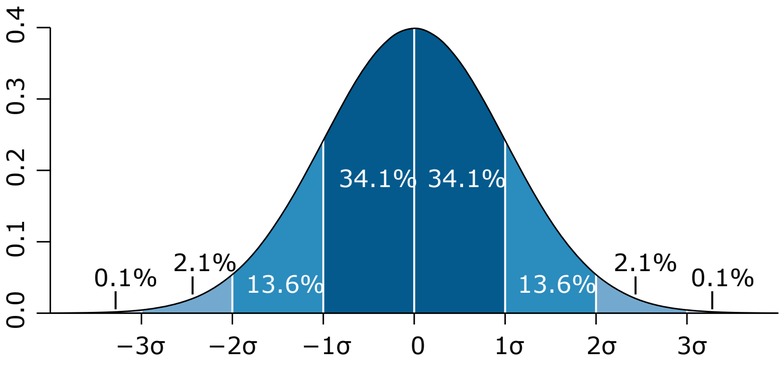

再考虑对$\mathbf{u}'$的归一化：

- 归一化量等于 $\sqrt{\sum_{i=1}^{d} X_i^2}$

设$X_i \sim \mathcal{N}(0,1)$是独立高斯

开根号后在$\sqrt{d}$附近

结合大概率$|\langle \mathbf{u}', \mathbf{v}_1 \rangle| \geq 1$，得到$|a_1| \geq \Omega(1/\sqrt{d})$

- 这个高斯平方和就是一个chi-square distribution，大概率聚集在d附近

将$\langle \mathbf{A}^t\mathbf{u}_0/\|\mathbf{A}^t\mathbf{u}_0\|, \mathbf{v}_1\rangle$表示成 a_i, λ_i

$\mathbf{A}^t\mathbf{u}_0/\|\mathbf{A}^t\mathbf{u}_0\|$是算法输出的向量

事实：$\mathbf{A}^t\mathbf{u}_0 = \sum_{i=1}^{d} a_i \mathbf{Q}\mathbf{D}^t\mathbf{Q}^\top \mathbf{v}_i = \sum_{i=1}^{d} a_i \lambda_i^t \mathbf{v}_i$

因此$|\langle \mathbf{A}^t\mathbf{u}_0, \mathbf{v}_1\rangle| = |a_1\lambda_1^t|$；另外：

$\sum_i a_i^2 = 1$

$$\|\mathbf{A}^t\mathbf{u}_0\|^2 = \|\sum_{i=1}^{d} a_i\lambda_i^t\mathbf{v}_i\|^2 = \sum_{i=1}^{d}(a_i\lambda_i^t)^2 \le a_1^2\lambda_1^{2t} + (a_1^2 + \ldots + a_d^2)\lambda_2^{2t}$$

$$\le a_1^2\lambda_1^{2t} + \lambda_2^{2t}$$

完成证明

已有：常数概率有 $|a_1| = |\langle \mathbf{u_0}, \mathbf{v_1} \rangle| \geq \Omega(1/\sqrt{d})$

$$\frac{|\langle \mathbf{A}^t \mathbf{u}_0, \mathbf{v}_1 \rangle|}{\|\mathbf{A}^t \mathbf{u}_0\|} \geq \frac{|a_1 \lambda_1^t|}{\sqrt{a_1^2 \lambda_1^{2t} + \lambda_2^{2t}}} \geq \frac{|a_1 \lambda_1^t|}{|a_1 \lambda_1^t| + |\lambda_2^t|}$$

则：

$$= 1 - \frac{|\lambda_2^t|}{|a_1 \lambda_1^t| + |\lambda_2^t|} \geq 1 - \frac{\lambda_2^t}{|a_1 \lambda_1^t|}$$

$$\geq 1 - O(\sqrt{d} \cdot (\lambda_2/\lambda_1)^t)$$

如果要计算第二PC呢?

一个基本方法

- idea：先找top PC，“排除” top PC后在新矩阵运行power iteration找第二PC
- 算法：
  - 用power iteration找第一PC $\mathbf{v}_1$
  - 对每个数据点$\mathbf{x}_i$做$\mathbf{x}_i \mapsto \mathbf{x}_i - \langle \mathbf{x}_i, \mathbf{v}_1 \rangle \mathbf{v}_1$
  - 在新数据集上做power iteration找到的第一PC就是第二PC（的近似）
- 可以递归进行下去来找第三、第四…

可以理解成把第一PC的分量删除，此时整个数据都只有垂直于第一PC的部分了，但依然包含第二PC

计算第二PC：基本方法的问题及解决方案

- $\mathbf{x}_i \mapsto \mathbf{x}_i - \langle \mathbf{x}_i, \mathbf{v}_1 \rangle \mathbf{v}_1$后会导致不再稀疏
- 解决方案：power iteration中的随机$\mathbf{u}_0$从垂直于$\mathbf{v}_1$的单位球面的部分均匀采样

简化：用± 1变量替代初始值的高斯

每维随机高斯的模长是随机的，但这里± 1向量的模长是确定的

- 可以把$\mathbf{u}_0$改成：每维是均匀± 1，最后再乘以归一化系数$1/\sqrt{d}$
- 数学结论：对一个每维均匀± 1向量$\mathbf{u}$和任意单位向量$\mathbf{v}$，有

$$\Pr[\langle \mathbf{u}, \mathbf{v} \rangle \geq 0.5] \geq \Omega(1)$$

- 所以常数概率，依然有$|\langle \mathbf{u}_0, \mathbf{v}_1 \rangle| \geq \Omega(1/\sqrt{d})$
- 之后的分析步骤都是一样的

扩展：如果$\lambda_1 = \lambda_2$呢?

思考：所有λ_i都想等呢?
是更难还是更简单?

- Power iteration依然会输出一个向量$\mathbf{u}$
- 但是性能保证不该继续看$\langle \mathbf{u}, \mathbf{v}_1 \rangle$，而是要$\mathbf{u}$在$\mathrm{span}(\mathbf{v}_1, \mathbf{v}_2)$上的投影尽量大
- 有类似的投影长度保证：

即找到一个“基本”在子空间中的向量

$\lambda_1 = \lambda_2$时principle component本来也不唯一，
任何一个落在$\mathrm{span}(\mathbf{v}_1, \mathbf{v}_2)$的向量都合法

投影长度 $\geq 1 - O(\sqrt{d})\left(\frac{\lambda_3}{\lambda_1}\right)^t$，也就是说可以继续看$\lambda_1$（或$\lambda_2$）与$\lambda_3$的gap

一般而言如果$\lambda_1 = \lambda_2 = \ldots = \lambda_i$，就可以有关于$\lambda_{i+1}/\lambda_1$的算法轮数保证

此时算法输出的是一个近似在$\mathbf{v}_1, \ldots, \mathbf{v}_i$ span里的向量

SVD

从rank说起

已知行与行之间互为一个倍数，请问如何补齐下面的矩阵?

$$\begin{bmatrix} 7 & ? & ? \\ ? & 8 & ? \\ ? & 12 & 6 \\ ? & ? & 2 \\ 21 & 6 & ? \end{bmatrix}$$

一般地，一个rank-1矩阵可以写成两个列向量$\mathbf{u}, \mathbf{v}$外积$\mathbf{u}\mathbf{v}^\top$的形式

$$\begin{bmatrix} 7 & 2 & 1 \\ 28 & 8 & 4 \\ 42 & 12 & 6 \\ 14 & 4 & 2 \\ 21 & 6 & 3 \end{bmatrix} = \begin{bmatrix} 1 \\ 4 \\ 6 \\ 2 \\ 1 \end{bmatrix} [721] = \mathbf{u}\mathbf{v}^\top = \begin{bmatrix} -u_1\mathbf{v}^\top- \\ -u_2\mathbf{v}^\top- \\ \vdots \\ -u_m\mathbf{v}^\top- \end{bmatrix}$$

rank-k

其他等价形式：例如最大的线性独立的行或者列的个数是k

- rank-k：可写成k个rank-1矩阵的和，并且不能写成任何$k-1$个rank-1矩阵和
  - 例如rank-2

$$\mathbf{A} = \mathbf{u}\mathbf{v}^\top + \mathbf{w}\mathbf{z}^\top = \begin{bmatrix} -u_1\mathbf{v}^\top + w_1\mathbf{z}^\top - \\ -u_2\mathbf{v}^\top + w_2\mathbf{z}^\top - \\ \vdots \\ -u_m\mathbf{v}^\top + w_m\mathbf{z}^\top - \end{bmatrix} = \begin{bmatrix} | & | \\ \mathbf{u} & \mathbf{w} \\ | & | \end{bmatrix} \begin{bmatrix} -\mathbf{v}^\top - \\ -\mathbf{z}^\top - \end{bmatrix}$$

rank-k矩阵的分解

根据刚才对于rank-2的讨论，一般而言，一个rank-k矩阵可以写成

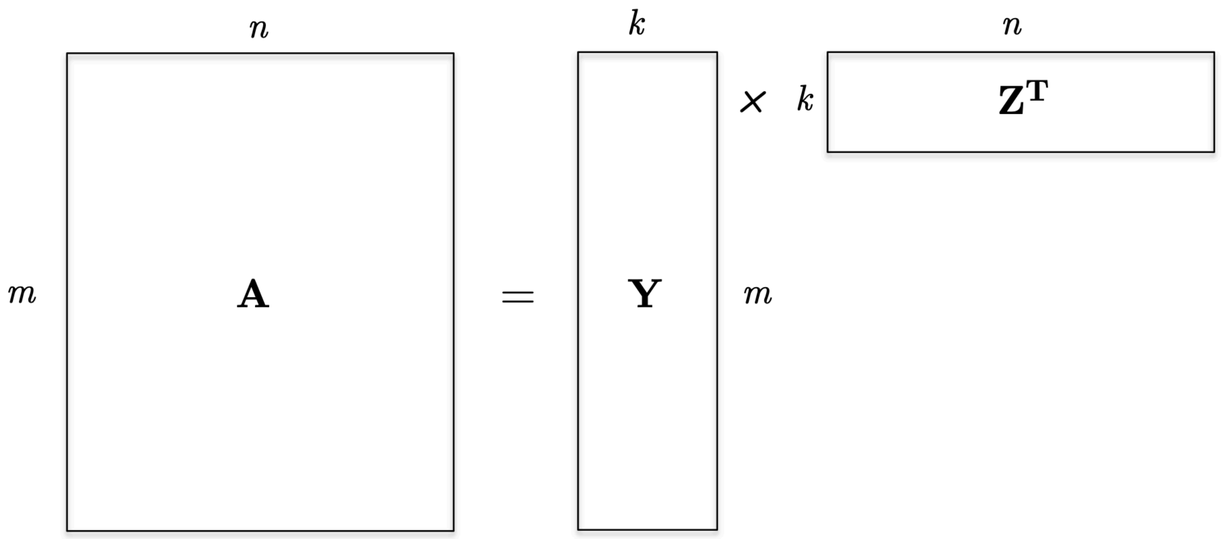

A的n列是$\mathbf{Y}$的k列的线性组合，且A的m行是$\mathbf{Z}^\top$的k行的线性组合

SVD

Singular Value Decomposition

U和V的每一列分别称作一个left或者right singular vector

- 任何矩阵$\mathbf{A}$可写成$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^\top$

每个元素叫做singular value，非0的个数等于矩阵的rank

  - $\mathbf{U}, \mathbf{V}$都是orthogonal matrix；$\mathbf{S}$是对角阵，每个元素都非负，一般按照降序排列

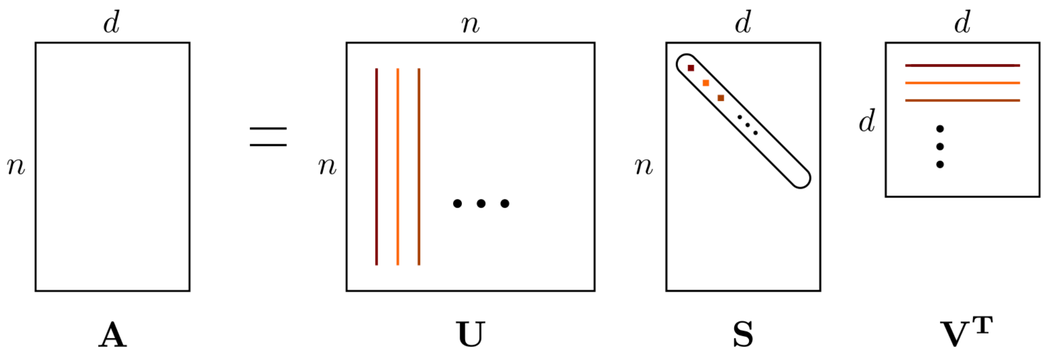

与rank的关系：$\mathbf{A} = \sum_{i=1}^{\min\{n,d\}} s_i \mathbf{u}_i \mathbf{v}_i^\top$

设rank是k，那么只有前k个s_i非零

每个$\mathbf{u}_i\mathbf{v}_i^\top$是一个rank-1矩阵，SVD就是一种显式将$\mathbf{A}$写成rank($\mathbf{A}$)个rank-1矩阵的方法

基于SVD的Low-rank Approximation

- 设$\mathbf{A}$的SVD是$\mathbf{U}\mathbf{S}\mathbf{V}^\top$，设$\mathbf{U}_k, \mathbf{V}_k$分别为矩阵取前$k$列，$\mathbf{S}_k$为取前k行和列
- 考虑$\mathbf{A}_k := \mathbf{U}_k\mathbf{S}_k\mathbf{V}_k^\top$，那么$\mathbf{A}_k$的rank不超过k

注：$\mathbf{A}$和$\mathbf{A}_k$的维度是一样的，只是rank不同

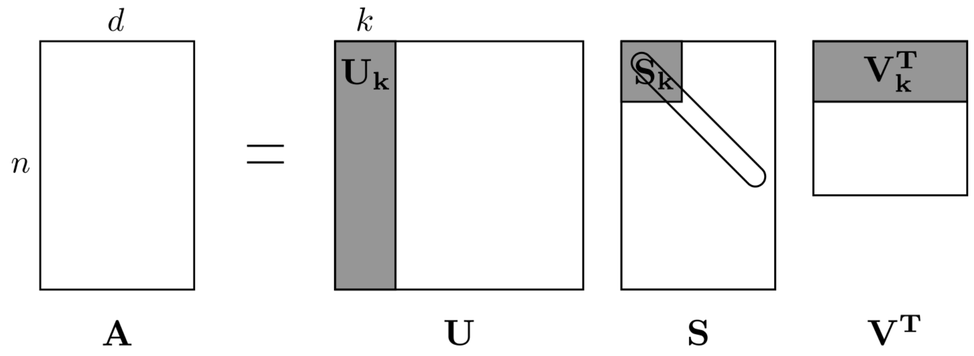

$\mathbf{A}_k$的高效表示

等价写法：$\mathbf{A}_k = \sum_{i=1}^{k} s_i \cdot \mathbf{u}_i \mathbf{v}_i^\top$

- 即rank-1求和的表达中只取singular value最大的k个rank-1矩阵

- 因此存储$\mathbf{A}_k$的代价非常小，是$k(n+d)$，而直接存储就是nd

- 而且与$\mathbf{A}_k$有关的矩阵计算也可以是与k有关的快速计算，例如与向量相乘$\mathbf{A}_k\mathbf{x}$

时间复杂度是多少?

$\mathbf{A}_k$是最优的Low-rank Approximation

结论：对任何$n \times d$矩阵$\mathbf{A}$，任何$k \geq 1$，任何rank-k的$n \times d$矩阵$\mathbf{B}$，有

$$\|\mathbf{A} - \mathbf{A}_k\|_F \leq \|\mathbf{A} - \mathbf{B}\|_F$$

也就是说在F范数的误差衡量下，$\mathbf{A}_k$具有最小的误差

其中对于任意矩阵$\mathbf{M}$，$\|\mathbf{M}\|_F := \sqrt{\sum_{i,j} M_{ij}^2}$

Frobenius norm

最优性的一些Intuition

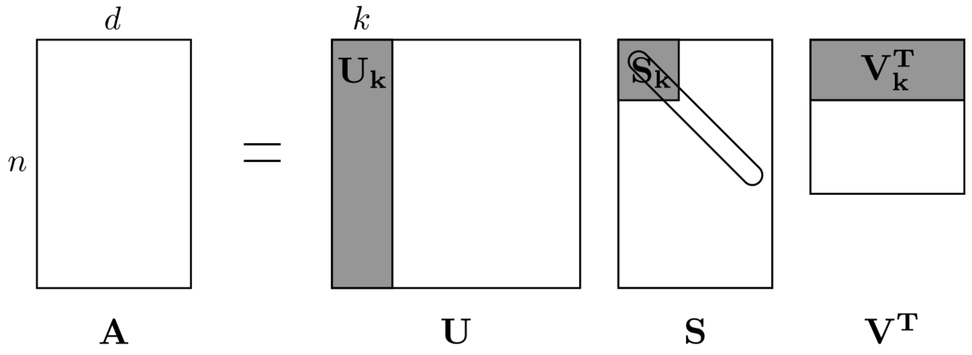

在$\mathbf{A} = \sum_{i=1} s_i \cdot \mathbf{u}_i \mathbf{v}_i^\top$表示中，$\mathbf{u}_i \mathbf{v}_i^\top$的“大小”是一样的

因为都是orthonormal的

但是singular value，s_i，决定了每项$\mathbf{u}_i \mathbf{v}_i^\top$的显著性

$\mathbf{A}_k = \sum_{i=1}^{k} s_i \cdot \mathbf{u}_i \mathbf{v}_i^\top$取最显著的k项，直觉上是对$\mathbf{A}$某种意义上最好的近似

Low-rank Approximation的典型应用

- 压缩/降维：nd到$k(n+d)$
- 去噪声：如果输入$\mathbf{A}$是某个low-rank数据源的带噪声采样
  - 那么选择合适的rank的low-rank approximation即可去噪声、精度损失小
- 矩阵还原
  - 很多矩阵有不少缺失值，尤其是例如电商网站用户-商品评分矩阵
  - 先将缺失项补0或者列均值，然后进行low-rank approximation

若原矩阵确实有low-rank结构且没有缺失太过多的信息，那么这是一种不错的还原方法

SVD与PCA的关系

SVD可以解PCA

一句话：SVD可以规约到PCA（即可以用SVD解PCA）

设$\mathbf{A} = \mathbf{X}^\top\mathbf{X}$，然后设$\mathbf{X}$的SVD为$\mathbf{X} = \mathbf{U}\mathbf{S}\mathbf{V}^\top$，则

$$\mathbf{A} = \mathbf{X}^\top\mathbf{X} = (\mathbf{U}\mathbf{S}\mathbf{V}^\top)^\top(\mathbf{U}\mathbf{S}\mathbf{V}^\top) = \mathbf{V}\mathbf{S}^\top\mathbf{U}^\top\mathbf{U}\mathbf{S}\mathbf{V}^\top = \mathbf{V}\mathbf{S}^2\mathbf{V}^\top$$

也就是写成了$\mathbf{Q}\mathbf{D}\mathbf{Q}^\top$的形式，因此$\mathbf{V}$的列就是$\mathbf{X}$的principle components

PCA只需要用$\mathbf{V}$，不需要$\mathbf{U}$

经常可以听到人说“PCA就是SVD”

解SVD：SVD求解有很成熟的solver，不建议自己写，最好直接调用

SVD与PCA的关系

Power iteration可以（部分）解SVD

- 另一个方向：PCA解SVD?
- 注意到设某个一般$\mathbf{X}$的SVD是$\mathbf{X} = \mathbf{U}\mathbf{S}\mathbf{V}^\top$则我们已经得出

$$\mathbf{A} = \mathbf{X}^\top\mathbf{X} = (\mathbf{U}\mathbf{S}\mathbf{V}^\top)^\top(\mathbf{U}\mathbf{S}\mathbf{V}^\top) = \mathbf{V}\mathbf{S}^\top\mathbf{U}^\top\mathbf{U}\mathbf{S}\mathbf{V}^\top = \mathbf{V}\mathbf{S}^2\mathbf{V}^\top$$

- 那么本来是用来解PCA的power iteration，也可以用来近似求$\mathbf{V}$的第一列
  - 也就是可以用来解一般矩阵$\mathbf{X}$的right singular vectors

* SVD的局限性

- SVD中$\mathbf{USV}^{\top}$的$\mathbf{U}$和$\mathbf{V}$都是dense的
  - 即使输入是sparse的，他们也还是dense的！
  - 另外它们不是原数据的行列，可解释性一般

U和V只是与数据的行/列具有某种隐性关系

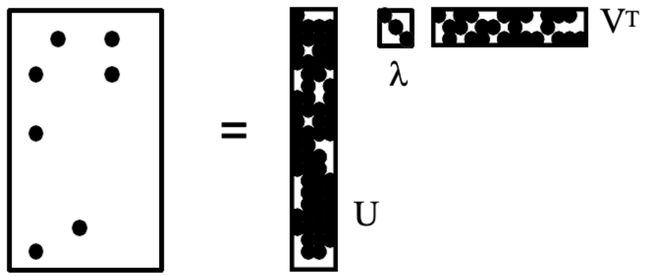

另一种Low-rank Approximation

- CUR decomposition
- 给定目标的rank k，把矩阵$\mathbf{A}$写成$\mathbf{A} = \mathbf{CUR}$
  - $\mathbf{U}$是dense的，但是rank是k
  - $\mathbf{C}$和$\mathbf{R}$分别是$\mathbf{A}$的某些列和行
- 目标：让$\|\mathbf{A} - \mathbf{CUR}\|_F \approx \|\mathbf{A} - \mathbf{A}_k\|_F$

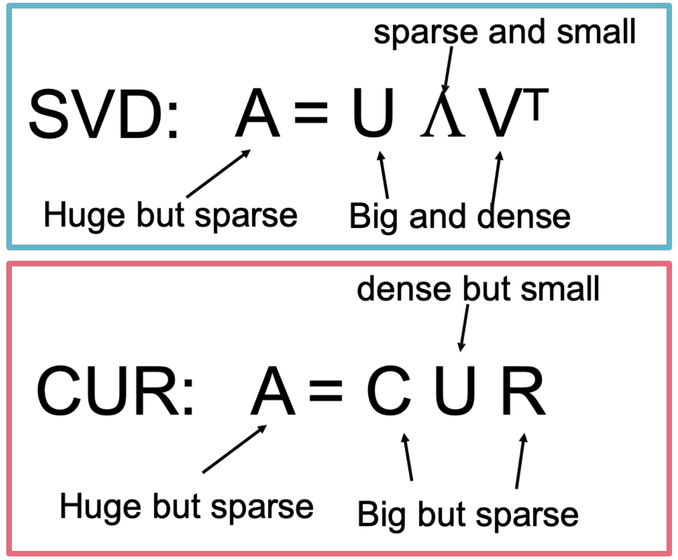

构造CUR的一种简单方法

- 按照行/列的ℓ_2范数进行重要性采样
- 会产生$\epsilon\|\mathbf{A}\|_F$的additive误差

[Frieze, Kannan, Vempala, JACM 04]

Sampling columns (similarly for rows):

Input: matrix $\mathbf{A} \in \mathbb{R}^{m\times n}$, sample size c
Output: $\mathbf{C}_d \in \mathbb{R}^{m\times c}$

1. for $x = 1 : n$ [column distribution]
2. $P(x) = \sum_i \mathbf{A}(i,x)^2 / \sum_{i,j} \mathbf{A}(i,j)^2$
3. for $i = 1 : c$ [sample columns]
4. Pick $j \in 1 : n$ based on distribution $P(x)$
5. Compute $\mathbf{C}_d(:,i) = \mathbf{A}(:,j)/\sqrt{cP(j)}$

采样次数是poly(k/ϵ)

CUR的State of the art

- [Boutsidis, Woodruff, STOC 14]
- $\mathbf{C}$和$\mathbf{R}$大小都是$O(k/\epsilon)$，$\mathbf{rank}(\mathbf{U}) = k$并且

$$\|\mathbf{A} - \mathbf{CUR}\|_F \leq (1+\epsilon)\|\mathbf{A} - \mathbf{A}_k\|_F$$

运行时间：$\mathrm{nnz}(\mathbf{A}) \cdot \mathrm{poly}\log n + \mathrm{poly}(k/\epsilon)$