程序设计实习（实验班-2025春）
大数据并行计算模型：MPC

授课教师：姜少峰
助教：管晏如、孔启皓、楼家宁、杨卓凡

Email: shaofeng.jiang@pku.edu.cn

大数据时代

甚至线性时间都不够高效

有效算法 = 多项式时间算法?

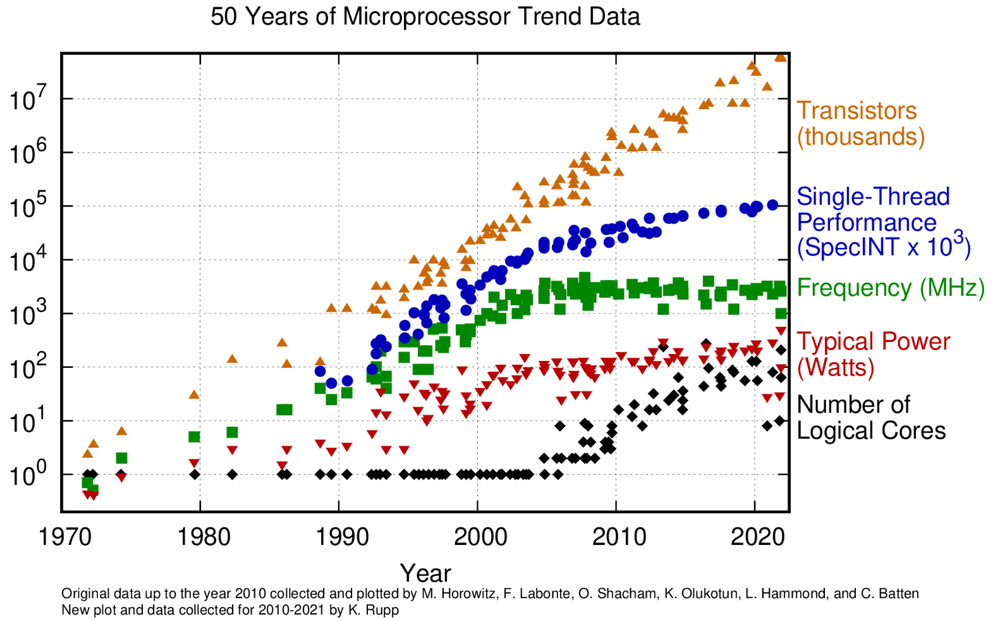

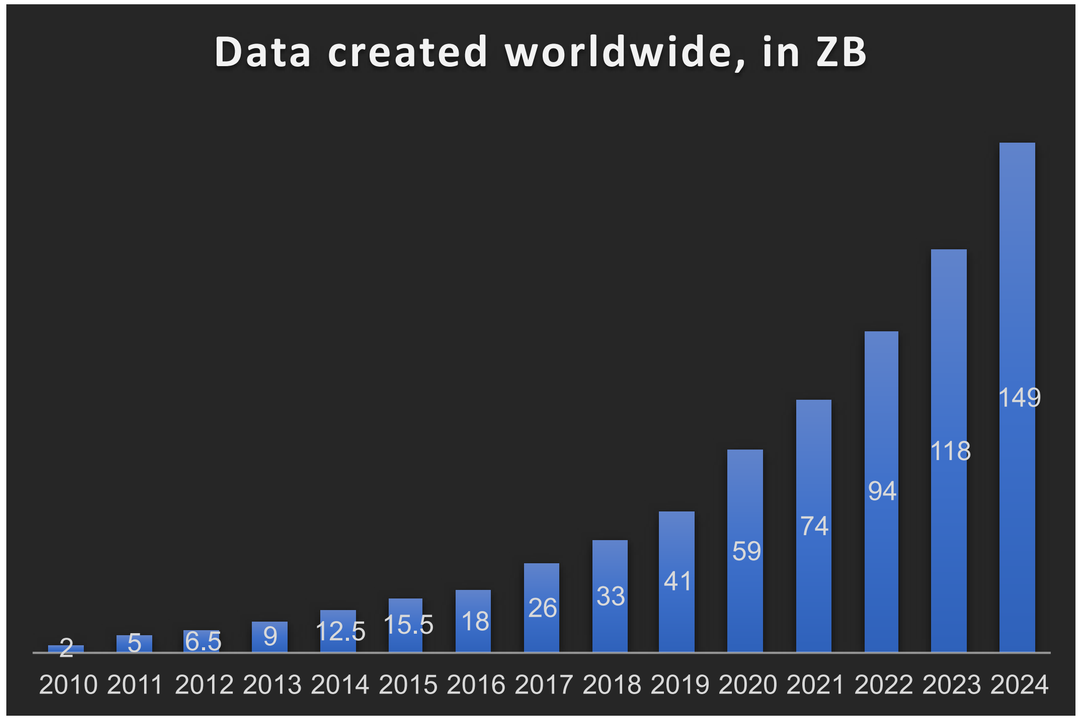

单个CPU：每秒10^{10}浮点运算；超级计算机：每秒10^{18}浮点运算

即使仅扫描一遍数据也不切实际；单CPU性能增速跟不上数据

“亚线性”计算模型

- 数据流算法：扫一遍数据流，用较小的空间计算
  - 路由器/物联网设备上直接做数据分析
- 并行算法

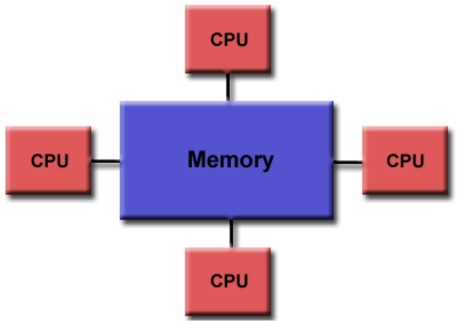

MapReduce框架是分布式计算最流行的软件实现

MapReduce

MapReduce：基本设定

- 设有规模n的输入数据，这些数据分散存储在若干机器上
  - 机器空间和机器个数：$n^{1-\epsilon}$

亚线性与输入规模n，否则trivial/不是大数据

- 在数据集上的计算通过某些抽象的基本操作进行

大体架构：Driver + Worker

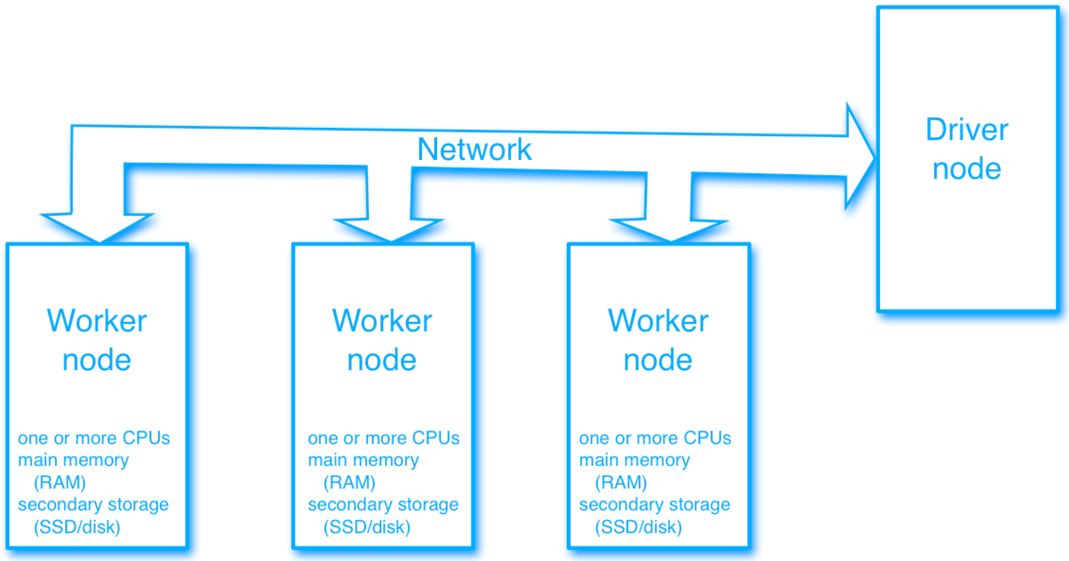

Driver将数据与任务分配给Worker

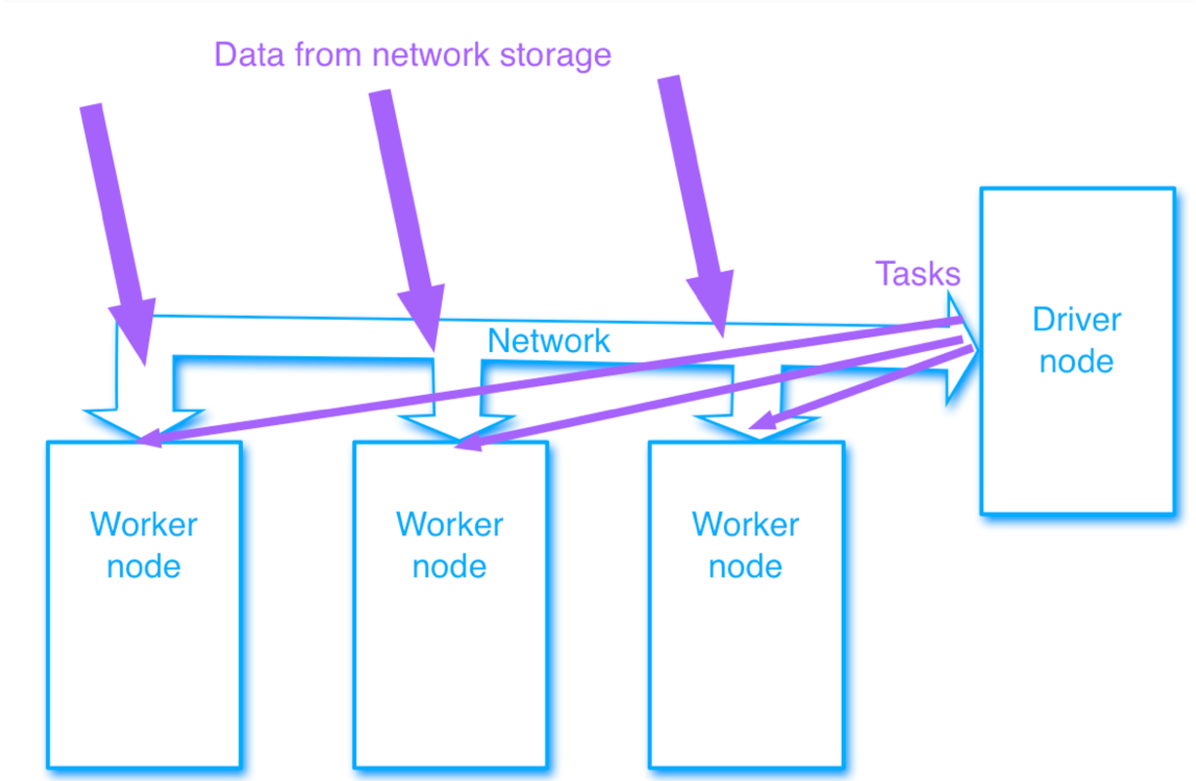

计算完成后Driver从Worker处收集结果

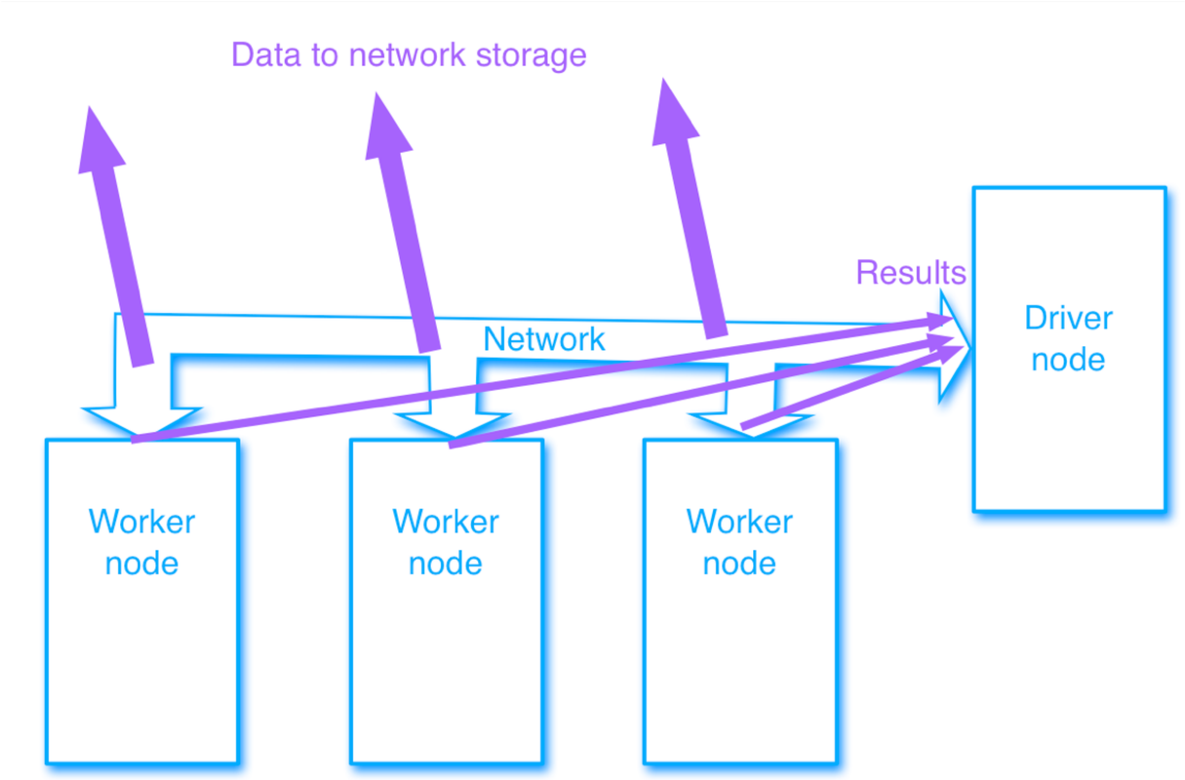

存储： Resilient Distributed Dataset (RDD)

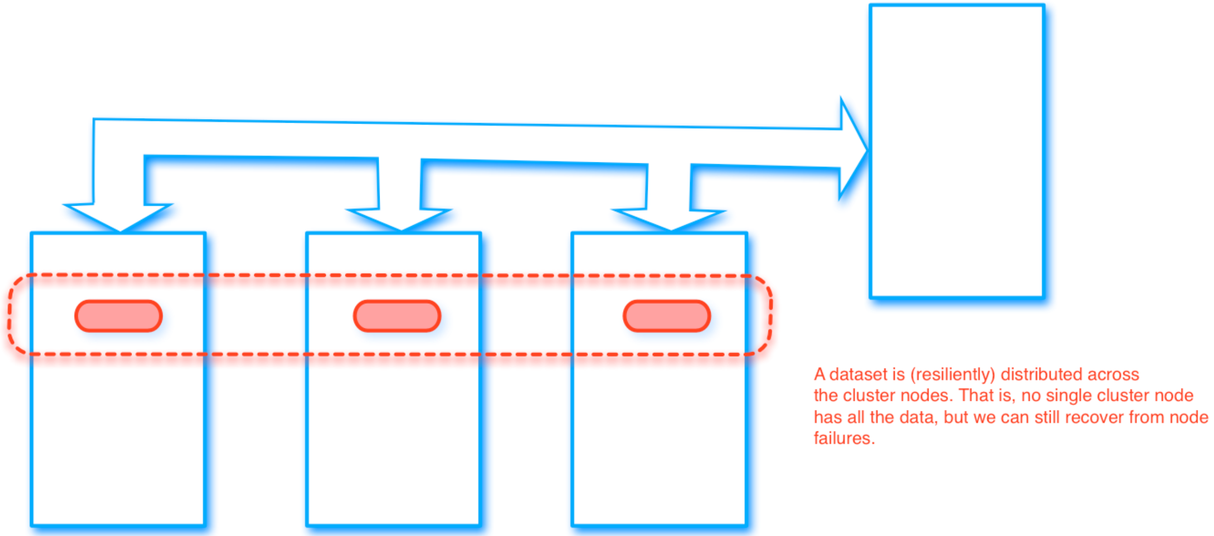

MapReduce

- MapReduce框架将RDD抽象出来，定义了若干种RDD上的基本操作
  - 这些基本操作的细节由MapReduce实现，使用者不需要关心
  - 换言之，MapReduce定义了几个基本操作/编程语言，想要操作MapReduce大数据的程序必须要用这几个基本操作写成

一般形式

[Karloff, Suri, Vassilvitskii, SODA 2010]

第一次将MapReduce框架的基本操作描述成数学语言

- 输入：一组(K, V)对

可以理解成把输入的每个(K, V)对映射成若干其他(K, V)对

- Mapper: 以数据中的每一对(K, V)为输入，输出一个或多个(K, V)对
- Reducer: 输入$K = K^*$的若干(K, V)，返回另一组同样以K^*为key的若干(K, V)
  - 即都是$(K^*, (V_1, \ldots, V_t))$形式
- 一轮 = Mapper + Reducer在整个数据集进行一次操作

例子：统计频数向量的ℓ_0-范数

即不同元素的个数

- 输入n个int分布式存储在一些机器上，想要计算这些数据的频数向量的ℓ_0-范数
- 如何用Mapper和Reducer的语言在O(1)轮完成?
  - 输入$\{(K, V) = (i, a_i)\}$
  - Mapper: 将每个(i, a_i) 映射成$(a_i, 1)$
  - Reducer: 输入$K = a_i$的所有tuple $(K = a_i, (V_1 = 1, \ldots, V_t = 1))$输出$(a_i, 1)$
  - Mapper: $(a_i, t) \mapsto (0, t)$, Reducer: $(0, (t_1, \ldots, t_m)) \mapsto (0, \sum_i t_i)$

切换关键字

由于关心ℓ_0，此处将a_i所有的出现汇总成1次
若要求ℓ_p范数应该输出(a_i, t^p)

对t求和这一简单操作的MapReduce语言描述

Apache Spark

- Apache Spark是一种非常流行的支持MapReduce的框架

Spark运行模式很灵活，可以尝试在自己单机配置运行，会利用多个CPU核心进行并行计算

Transformations	$map(f : T \Rightarrow U)$	:	$RDD[T] \Rightarrow RDD[U]$
	$filter(f : T \Rightarrow Bool)$	:	$RDD[T] \Rightarrow RDD[T]$
	$flatMap(f : T \Rightarrow Seq[U])$	:	$RDD[T] \Rightarrow RDD[U]$
	$sample(fraction : Float)$	:	$RDD[T] \Rightarrow RDD[T]$ (Deterministic sampling)
	$groupByKey()$	:	$RDD[(K, V)] \Rightarrow RDD[(K, Seq[V])]$
	$reduceByKey(f : (V, V) \Rightarrow V)$	:	$RDD[(K, V)] \Rightarrow RDD[(K, V)]$
	$union()$	:	$(RDD[T], RDD[T]) \Rightarrow RDD[T]$
	$join()$	:	$(RDD[(K, V)], RDD[(K, W)]) \Rightarrow RDD[(K, (V, W))]$
	$cogroup()$	:	$(RDD[(K, V)], RDD[(K, W)]) \Rightarrow RDD[(K, (Seq[V], Seq[W]))]$
	$crossProduct()$	:	$(RDD[T], RDD[U]) \Rightarrow RDD[(T, U)]$
	$mapValues(f : V \Rightarrow W)$	:	$RDD[(K, V)] \Rightarrow RDD[(K, W)]$ (Preserves partitioning)
	$sort(c : Comparator[K])$	:	$RDD[(K, V)] \Rightarrow RDD[(K, V)]$
	$partitionBy(p : Partitioner[K])$	:	$RDD[(K, V)] \Rightarrow RDD[(K, V)]$
Actions	$count()$	:	$RDD[T] \Rightarrow Long$
	$collect()$	:	$RDD[T] \Rightarrow Seq[T]$
	$reduce(f : (T, T) \Rightarrow T)$	:	$RDD[T] \Rightarrow T$
	$lookup(k : K)$	:	$RDD[(K, V)] \Rightarrow Seq[V]$ (On hash/range partitioned RDDs)
	$save(path : String)$	:	Outputs RDD to a storage system, *e.g.*, HDFS

Table 2: Transformations and actions available on RDDs in Spark. Seq[T] denotes a sequence of elements of type T.

MPC：
抽象的MapReduce计算模型

MPC (Massively Parallel Computing)

这里是指一般意义上抽象的数据点，可以是一条图上的边，可以是一个$\mathbb{R}^d$的点等等
总体要求是：假设一个点占据一个存储单位

- 输入数据：n个“点”，任意分布在若干机器上

$0 < \alpha < 1$是一个常数

- 每台机器的存储至多是$s = o(n)$，典型设定是$s = n^\alpha$

m不是独立参数，而是取决于n和s

- 定义机器个数为$m = \Omega(n/s)$
- 在一轮中：每台机器可以发信息到任何机器、从任何机器接受信息，但每台机器的总收发量必须是$O(s)$的
- 一般我们忽略$\text{poly}\log n$的factor

例如上述的机器数m允许$(n/s \cdot \text{poly}\log n)$，
每轮每台机器总通信可以是$O(s \cdot \text{poly}\log n)$

关于分布式算法的输出

- 输出一般也是分布式的，因为输出很大且无法存储在一台机器上
- 具体设定取决于问题，例如
  - 排序: 每个元素存储自己在排序后的rank
  - 图的匹配: 每个点存储自己匹配到的点的ID
  - 对于图上的MST：每条输入边存一个Yes/No表示自己是否被选进MST

MPC算法

- 一段相同的算法/程序需要同时运行在所有机器上
- 目标：一般追求$\mathrm{poly}\log n$轮，最好是$O(1)$轮
- 理论上，主要追求轮数，本地计算可以先忽略不计

但一般设计的算法的本地计算也是高效的

MPC基本算法

Broadcast广播

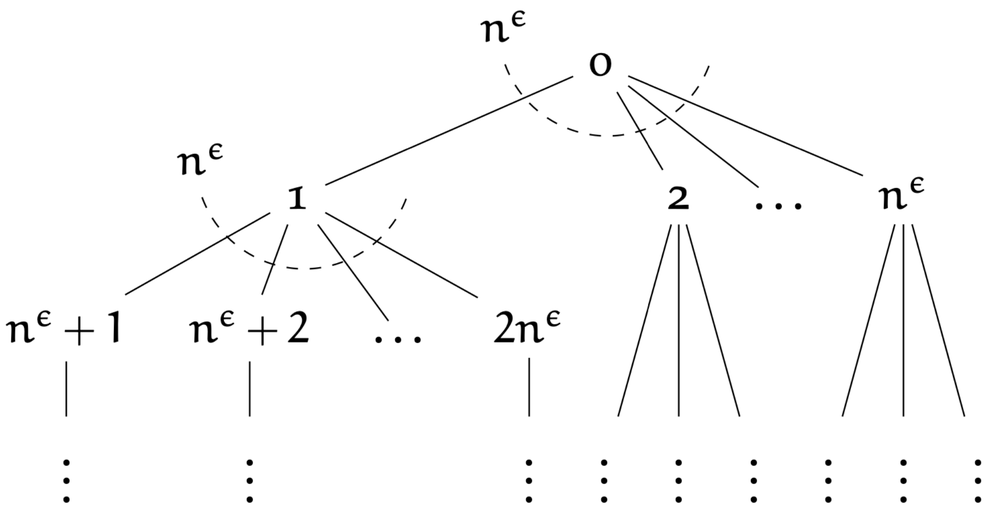

- 设机器1存储了一个长度为t的信息A
- 任务：将信息A传送/广播给所有机器
  - 直接发给大家是不行的，因为会爆内存
- 设：机器内存$s \geq t^{1+\epsilon}$

一开始，为不爆通信限制O(s)，机器1将长度t的信息A用1轮发送给t^ϵ个其他机器
收到信息的机器再用1轮每个发给其他t^ϵ个机器，以此类推

- Claim: 可在$O(\log_s n)$轮完成 (考虑一个t^ϵ-叉树进行广播)

思考：要是$s = O(t)$呢?

广播的“逆”过程：Converge-cast

- Converge-cast：从每个机器上汇总长度为t的信息，到一个leader（如机器1）
- 例如：
  - 每个机器有一个t-维int向量，想要所有机器的t-维向量的求和
- Claim: 可达到与broadcast相同的轮数

将converge-cast看作是“反向”的广播

简单应用：单点查询

- 例如，考虑n个分布存储在机器上的$\mathbb{R}^d$上的点
- 给一个query point $p \in \mathbb{R}^d$，要求返回p在n个点中的ℓ_2最近邻
- $O(\log_s n)$轮可以做到：

  比离线算法要容易：离线设定并不能有效支持这种暴力算法

  - 把p broadcast给所有机器，所有机器求本地点到p最近邻
  - converge-cast找这些最近邻中的最近邻，汇总到机器1

事实上不止可以回答一个query point，可以回答一个batch，只要batch size $\leq s^{1-\epsilon}$

重要工具：排序

- 分布式输入$\{a_i\}_{i=1}^n$
- 要求将a_i升序排列使得位次相同的元素占据连续编号的一段机器
- 结论：可以在$O(\mathrm{poly}\log_s n)$轮完成

在$s = n^\alpha$的典型设定下，这个轮数就是$O(1)$的

MPC实现思路：基于Multi-pivot快速排序

- 基于multi-pivot排序方法

回忆：如果输入数组是$(2,3,7,5,4,10,8)$且pivot是下标$\{2,4\}$，那么就需要根据$a_2 = 3, a_4 = 5$来划分输入，得到值 $< 3, [3,5], > 5$三个部分，即$(2), (3,4,5), (7,8,10)$三个新序列；之后要在三个新序列递归排序

- 如何在MPC实现?
  - 找1台机器选好pivot，告知所有机器，每个机器根据pivot划分数据
  - 为实现递归：将每个pivot区间汇总起来发送到连续编号的机器段上

然后在每段机器上进行递归排序

MPC实现

这里选任何s^t (t < 1)都可以，是为了让broadcast在$O(\log_s n)$轮可做

- 在1号机器选$\sqrt{s}$个$\{1,\ldots,n\}$上的随机pivot，然后broadcast给所有机器
- 每台机器统计每个pivot区间有多少元素，并用converge-cast给1号机

这里pivot区间指的是例子中的三个新序列
注意到每个区间可以很大、横跨多台机器，因此需要converge-cast

- 1号机器再把得到的每个pivot区间的元素个数broadcast给所有机器

是一个长度是$\sqrt{s}+1$的数组/向量

- 此时每台机器同时知道：所有pivot，和每个pivot区间长度

MPC实现

- 回忆：此时每台机器同时知道：所有pivot，和每个pivot区间长度
- 我们想让每个pivot区间都对应一段连续编号的机器
  - 机器的编号可以用区间长度来计算

这样所有机器都知道每个pivot区间的数据
应该放到哪些个连续机器上

- 因此每台机器：
  - 根据pivot划分本机的数据，将每个区间的数据发送到对应编号段的机器

小细节：比如一个编号段有100台机器，应该如何决定发给哪台?
难在每台机器都有一部分数据要发到这100台上，而机器间很难协调负载均衡
因此应该用随机负载均衡技术：发给这100台的随机的一台

排序轮数分析

- pivot个数是$\sqrt{s}$，因此递归产生的子问题大概规模在$n/\sqrt{s}$
  - 总递归层数$O(\log_s n)$
- 每轮递归，所有连续的机器段内进行若干次broadcast和converge-cast
  - 这部分是$O(\log_s n)$
- 总体上：$O(\log_s^2 n)$

Mapper和Reducer都如何在MPC实现?

本机对每个元素直接处理

- Mapper: 以单独的一对(K, V)为输入，输出一系列(K, V)对
- Reducer: 以K^*的相同若干(K, V)为输入，返回另一组同样以K^*为key的(K, V)

此处可以使用排序来将同一个K下的V整理到一起

MPC是一种“更灵活”的“MapReduce”模型

直接应用：Linear Regression的MPC算法

- linear regression：输入是$X \in \mathbb{R}^{n \times d}$
  - 以分布式稀疏方式给出：(i, j, X_{ij})
- 如果假定d很小而n很大，具体来说$\mathrm{poly}(d) \ll s \ll n$
- 我们学过的方法：先降维，把n降成大概$\mathrm{poly}(d)$
  - 然后在$\mathrm{poly}(d) \times d$矩阵$\hat{X}$上用公式$w = (\hat{X}^\top \hat{X})^{-1} \hat{X}^\top \hat{y}$

回忆：降维矩阵S

设随机$S \in \mathbb{R}^{m\times n}$每列只有一个均匀随机位置非0，且该元素取均匀随机$\{-1,1\}$

$$S = \begin{pmatrix} 0 & 0 & \cdots & 1 & 0 & -1 \\ \vdots & \vdots & \cdots & \vdots & \vdots & \vdots \\ 1 & \vdots & \cdots & \vdots & \vdots & \vdots \\ \vdots & 1 & \cdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & 0 & -1 & 0 \end{pmatrix}$$

[Clarkson-Woodruff, STOC 13]

定理：用$A' = S$替代JL矩阵A，$m = O(\epsilon^{-2}d^2 \cdot \mathrm{poly}\log(\epsilon^{-1}d))$有类似保证

$$\forall v \in \mathcal{U}, \quad \Pr[\|A'v\|^2 \in (1 \pm \epsilon) \cdot \|v\|^2] \geq 0.9$$

回忆$\mathcal{U}$是$\mathbb{R}^n$的d维子空间

如何在MPC计算SX?

- 对$i \in [n]$，设S的第i列选取的随机行为$\pi(i)$
- 性质：设$M = SX$，则X_{ij}只会影响$M_{\pi(i),j}$
- MPC算法：将(i, j, X_{ij})按照i为关键字排序，计算$\pi(i)$并broadcast给$(i, \cdot, \cdot)$
  - 再按$\pi(i)$为第一关键字、j为第二关键字排序(i, j, X_{ij})
- 最后再将M直接发送到机器1，进行本地求解$w = (\hat{X}^\top \hat{X})^{-1} \hat{X}^\top \hat{y}$

π需要$\Omega(n)$空间存储，无法预先在一台机器生成，只能在每个i的那一组分布式生成

轮数?

此时排序后的一段可汇总出$M_{\pi(i),j}$的值

矩阵大小$\mathrm{poly}(d)$，根据假设可以放在一台机器上

MPC上的算法研究

MPC算法研究概述

- MPC算法是新兴算法领域，与大数据处理的关系密切
  - 也受到了以Google Research为代表的工业界实验室的大力推动
- 一个研究主线是为各种不同输入数据的设定和问题设计MPC算法：
  - 图数据
  - $\mathbb{R}^d$数据
  - 字符串数据等

根本挑战和细分设定

- 根本挑战：sublinear的空间
- 又称为fully scalable：即算法需要可以处理任何$s = n^{\epsilon}$，且最好是$O_{\epsilon}(1)$轮

即允许使用任意弱的机器

- 前述的基本算法都是fully scalable的

- 对于一般问题：fully scalable经常很困难，有时根据问题参数考虑细分设定

图数据的MPC算法：细分Regime

- 图数据： 设有n个顶点，输入是图的边集

数据至多可以是$O(n^2)$大小

- 注意到输入规模其实是边数m，而不是n
- 根据机器空间s与n的关系分为三个regime：
  - super-linear：$s = n^{1+\epsilon}$，near-linear：$s = \tilde{O}(n)$，sub-linear：$s = n^{1-\epsilon}$

连点集和问题的解都存不下

能存下点集和典型问题，例如MST/matching的解
还能有n^{ϵ}空余做别的

能存下点集和很多典型问题的解
但是没有很多额外空间做其他事情

最小生成树MST的MPC算法

Super-linear Regime下的MST

Filtering技术 [Karloff, Suri, Vassilvitskii, SODA 2010]

边数太少没意义：基本上可以发到一台机器上运行经典算法解决掉

- 空间$s = \tilde{O}(n^{1+\epsilon})$，且设$|E| = m = n^{1+c}$
- 结论: 存在MPC算法能在$O(c/\epsilon)$轮计算最小生成树的精确解

Algorithm: MST(V,E)

η就是我们的s

if $|E| < \eta$ **then**
  Compute $T^* = MST(E)$
  return T^*
end if
$\ell \leftarrow \Theta(|E|/\eta)$
Partition E into $E_1, E_2, \ldots, E_\ell$ where $|E_i| < \eta$ using a universal hash function $h : E \to \{1, 2, \ldots, \ell\}$.
In parallel: Compute T_i, the minimum spanning tree on $G(V, E_i)$.
return MST$(V, \cup_i T_i)$

如果当前边数少于s了，就可以发到一台机器解决

否则，把边集均匀分配到每台机器上，在每台机器上收到的边集E_i用传统算法计算MST

细节：一轮converge-cast之后，会收集到n^c个MST边集的并。此时，需要把这个并集的MST求出来，再继续converge cast

最后需要一个converge-cast来汇总每台机器上的MST

Near-linear Regime下的MST

Linear Sketching技术

- 这里介绍一个一般方法：数据流算法经常可以转成MPC算法！
- 回忆：对于图数据流，我们得到了一个$\tilde{O}(n/\epsilon)$空间的$(1+\epsilon)$近似MST的算法
- 具体来说：我们对每个顶点v维护了总大小$\tilde{O}(1)$的若干ℓ_0-采样结构
  - 重点：这些ℓ_0-采样结构都是linear-sketch

回忆linear sketch重要性质：可合并

具体实现

- 将边按照较小顶点号排序

  回忆：排序操作可以在$O(\log_s n)$轮完成

  - 这样与每个顶点邻接的边都放在了某同一台机器上
- 对于每个顶点v，将邻接边插入streaming算法维护的$\tilde{O}(1)$大小的一众ℓ_0结构里
- 把每个顶点的数据结构直接发到1号机器

  注意这里不需要converge-cast来汇总，并且不会爆空间（为什么？）

  - 此时1号机器就有了整个图的streaming数据结构，可直接运行查询得到MST

类似的：欧氏空间近似直径

- 回忆：数据流sparse recovery算法可在$O(\epsilon^{-d}\text{poly}\log n)$空间$(1+\epsilon)$近似直径
- MPC算法：
  - 机器将本机点集喂给该数据流算法，得到一个$O(\epsilon^{-d}\text{poly}\log n)$大小的结构
  - 使用converge-cast把所有的结构“求和”，汇总到机器1
  - 机器1继续运行求直径的算法，得出直径

因为是linear sketch，所以可以相加

根本挑战：Sub-linear Regime

MST的结果

- 一般图仍只有最坏情况$o(\log n)$-轮的$(1+\epsilon)$-近似
  - 该设定也有$\Omega(\log n)$轮的conditional lower bound
- 如果input满足三角形不等式（metric space）
  - 一般metric有$O(\log(\epsilon^{-1}) + \log\log n)$-轮的$(1+\epsilon)$-近似

    [Azarmehr, Behnezhad, Jayaram, Łącki, Mirrokni, Zhong, SODA 25]
  - 低维欧氏有$O(1)$-轮的$(1+\epsilon)$-近似，但local space要求$2^{\Omega(d)}$

    [Andoni, Nikolov, Onak, Yaroslavtsev, STOC 14]

Sub-linear Regime的最基本问题：MIS

- MIS = Maximal Independent Set
- 输入：无向图$G(V, E)$
- IS是一个$S \subseteq V$ such that $\forall x \neq y \in S$有$\{x, y\} \notin E$
- MIS就是极大的IS，即无法加入任何点$u \in V$使该集合继续是IS

- 特点：计算一组解天然需要很多（轮）通信，但验证一组解是简单的

经典算法：Luby

[Luby, SICOMP 1986]

- 本来定义在Local Model上
- Local Model：
  - 输入网络拓扑图$G(V, E)$，每个vertex有一台机器，该机器知道自己的邻居信息
  - 每台机器每轮可以向所有直接邻居发送任意长度的信息
- **Claim**: 在Local Model下，$O(\log n)$-轮可以计算一个拓扑图的MIS
  - “计算”的意思：每台机器赋予Yes或者No，代表是否选入MIS

Luby算法过程

1. 初始化标记所有点un-visited，MIS从属为No
2. for $i = 1, \ldots, O(\log n)$
3. 每台un-visited机器j生成一个$[0,1]$上的均匀随机数h_j
4. 每台un-visited机器$j \in P$若$h_j = \min\{h_k : k \in P \cap N(j)\}$则赋$j$为Yes
5. 每台un-visited机器j若$\{j\} \cup N(j)$有赋Yes的，则标记j为visited

该规则标记Yes的点构成IS

可以理解成MIS的点及其邻居都在本轮for循环“删除”

主要Claim：a) 算法每轮找到的一定是MIS；b) 每轮期望会删掉一半的边

https://jshun.csail.mit.edu/simple-analysis.pdf给出了一个简单的分析

Luby的MPC实现

- Claim：Luby的每次for循环可以用$O(1)$个MPC轮实现
  - 随机数生成可在1轮完成
  - 其余步骤：
    - 每条无向边$\{u, v\}$复制成有向边(u, v)和(v, u)
    - 将有向边按照第一顶点为关键字排序
    - 连续段对应一个顶点的邻居，可直接进行统计（converge-cast etc）

MIS的Fully Scalable MPC算法：目前进展

- Luby的算法依然是最坏情况下已知最好的
- 有一些conditional lower bound结果一定程度上说$\log n$不可以显著改进
- 对特例可能做更好，例如bounded degree图 [Ghaffari, SODA 16]
- 更多近期进展参考Mohsen Ghaffari的工作

聚类问题的Fully Scalable MPC算法

- 聚类问题：k-median, k-means, k-center
- 若允许本地空间$s \geq \Omega(k)$，则较为容易、存在$O(1)$轮$(1+\epsilon)$-近似

  并不fully scalable
- Fully scalable并且$O(1)$轮的算法：
  - k-median: $O(\log^{1.5})$近似 [Cohen-Addad, Lattanzi, Norouzi-Fard, Sohler, Svensson, NeurIPS 21] [Ahanchi, Andoni, Hajiaghayi, Knittel, Zhong, SPAA 23]
  - k-center: 低维2-近似，高维$O(\log n/\log\log n)$-近似 [Czumaj, Gao, Ghaffari, J, ICALP 25]
  - k-means: 即使2维也没有结果